

Separación de componentes con Redes Neuronales

Biuse Casaposa
Grupo de Cosmología Observacional e Instrumentación
IFCA

Separación de componentes del fondo cósmico de microondas con redes neuronales

- Fondo cósmico de microondas (o CMB) ¿Qué es?
 - Separación de componentes del CMB
-

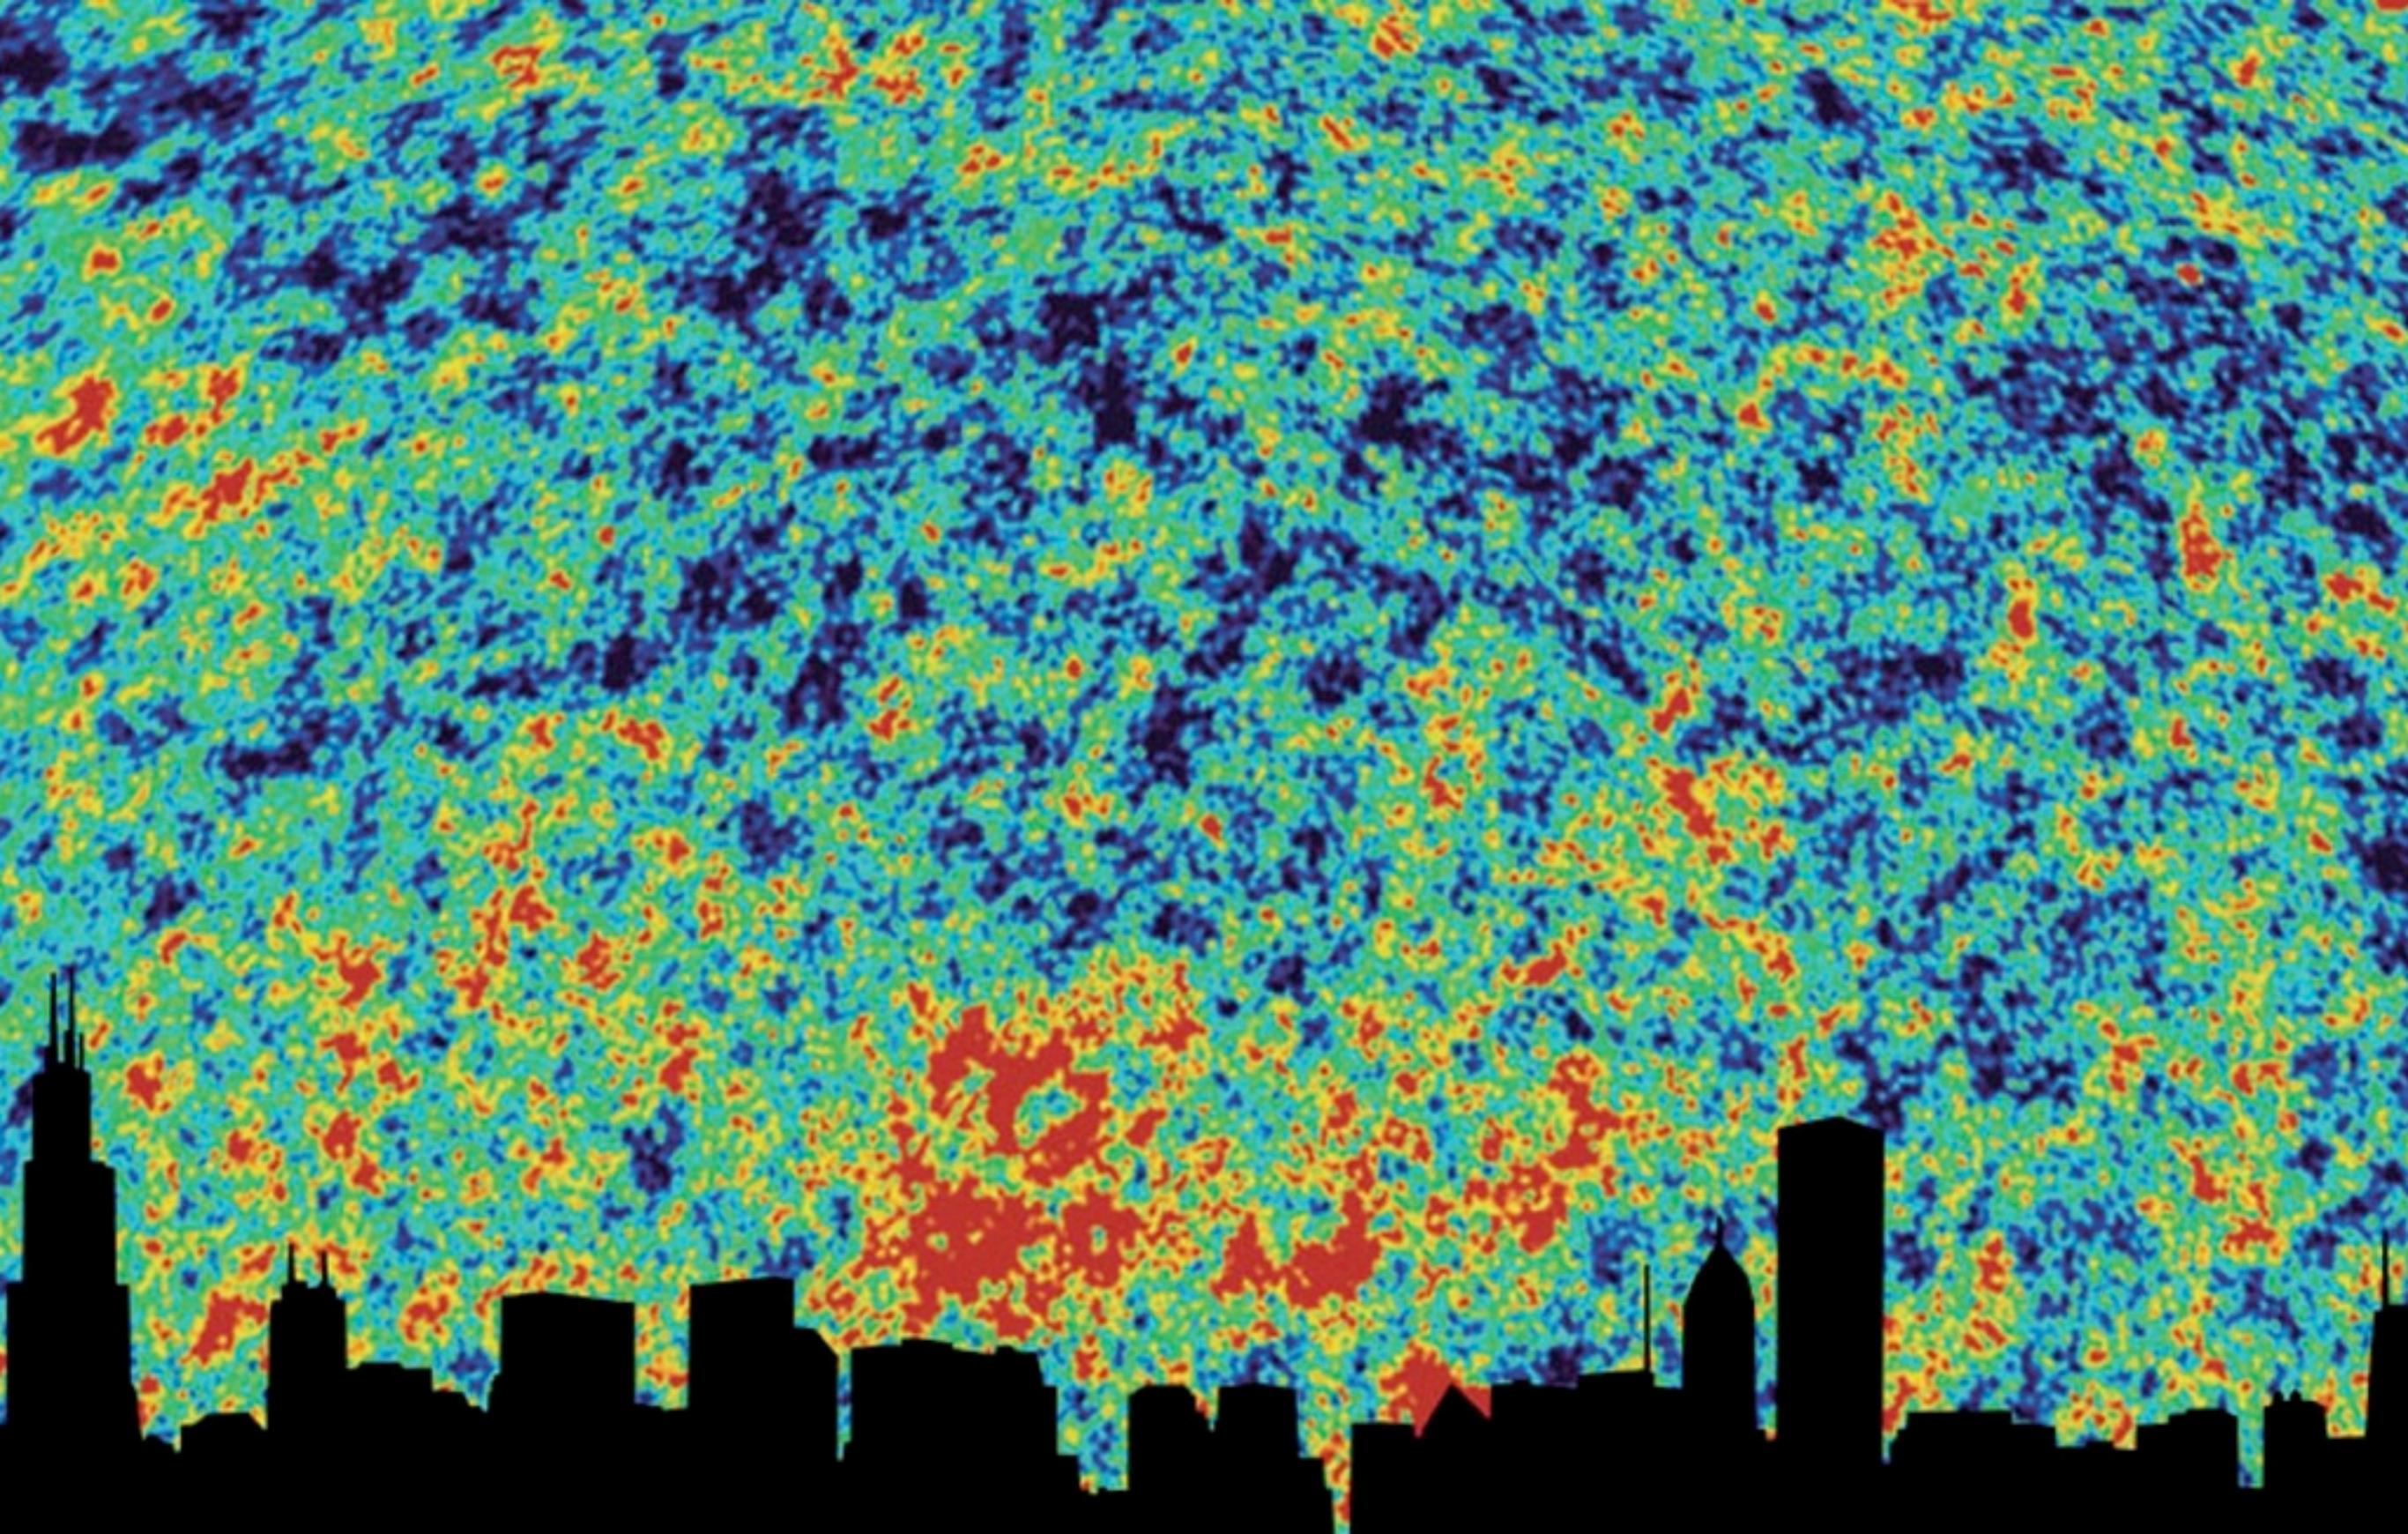
- Problema a resolver.
 - Kaggle challenge
-

- Lab (3~4 horas)

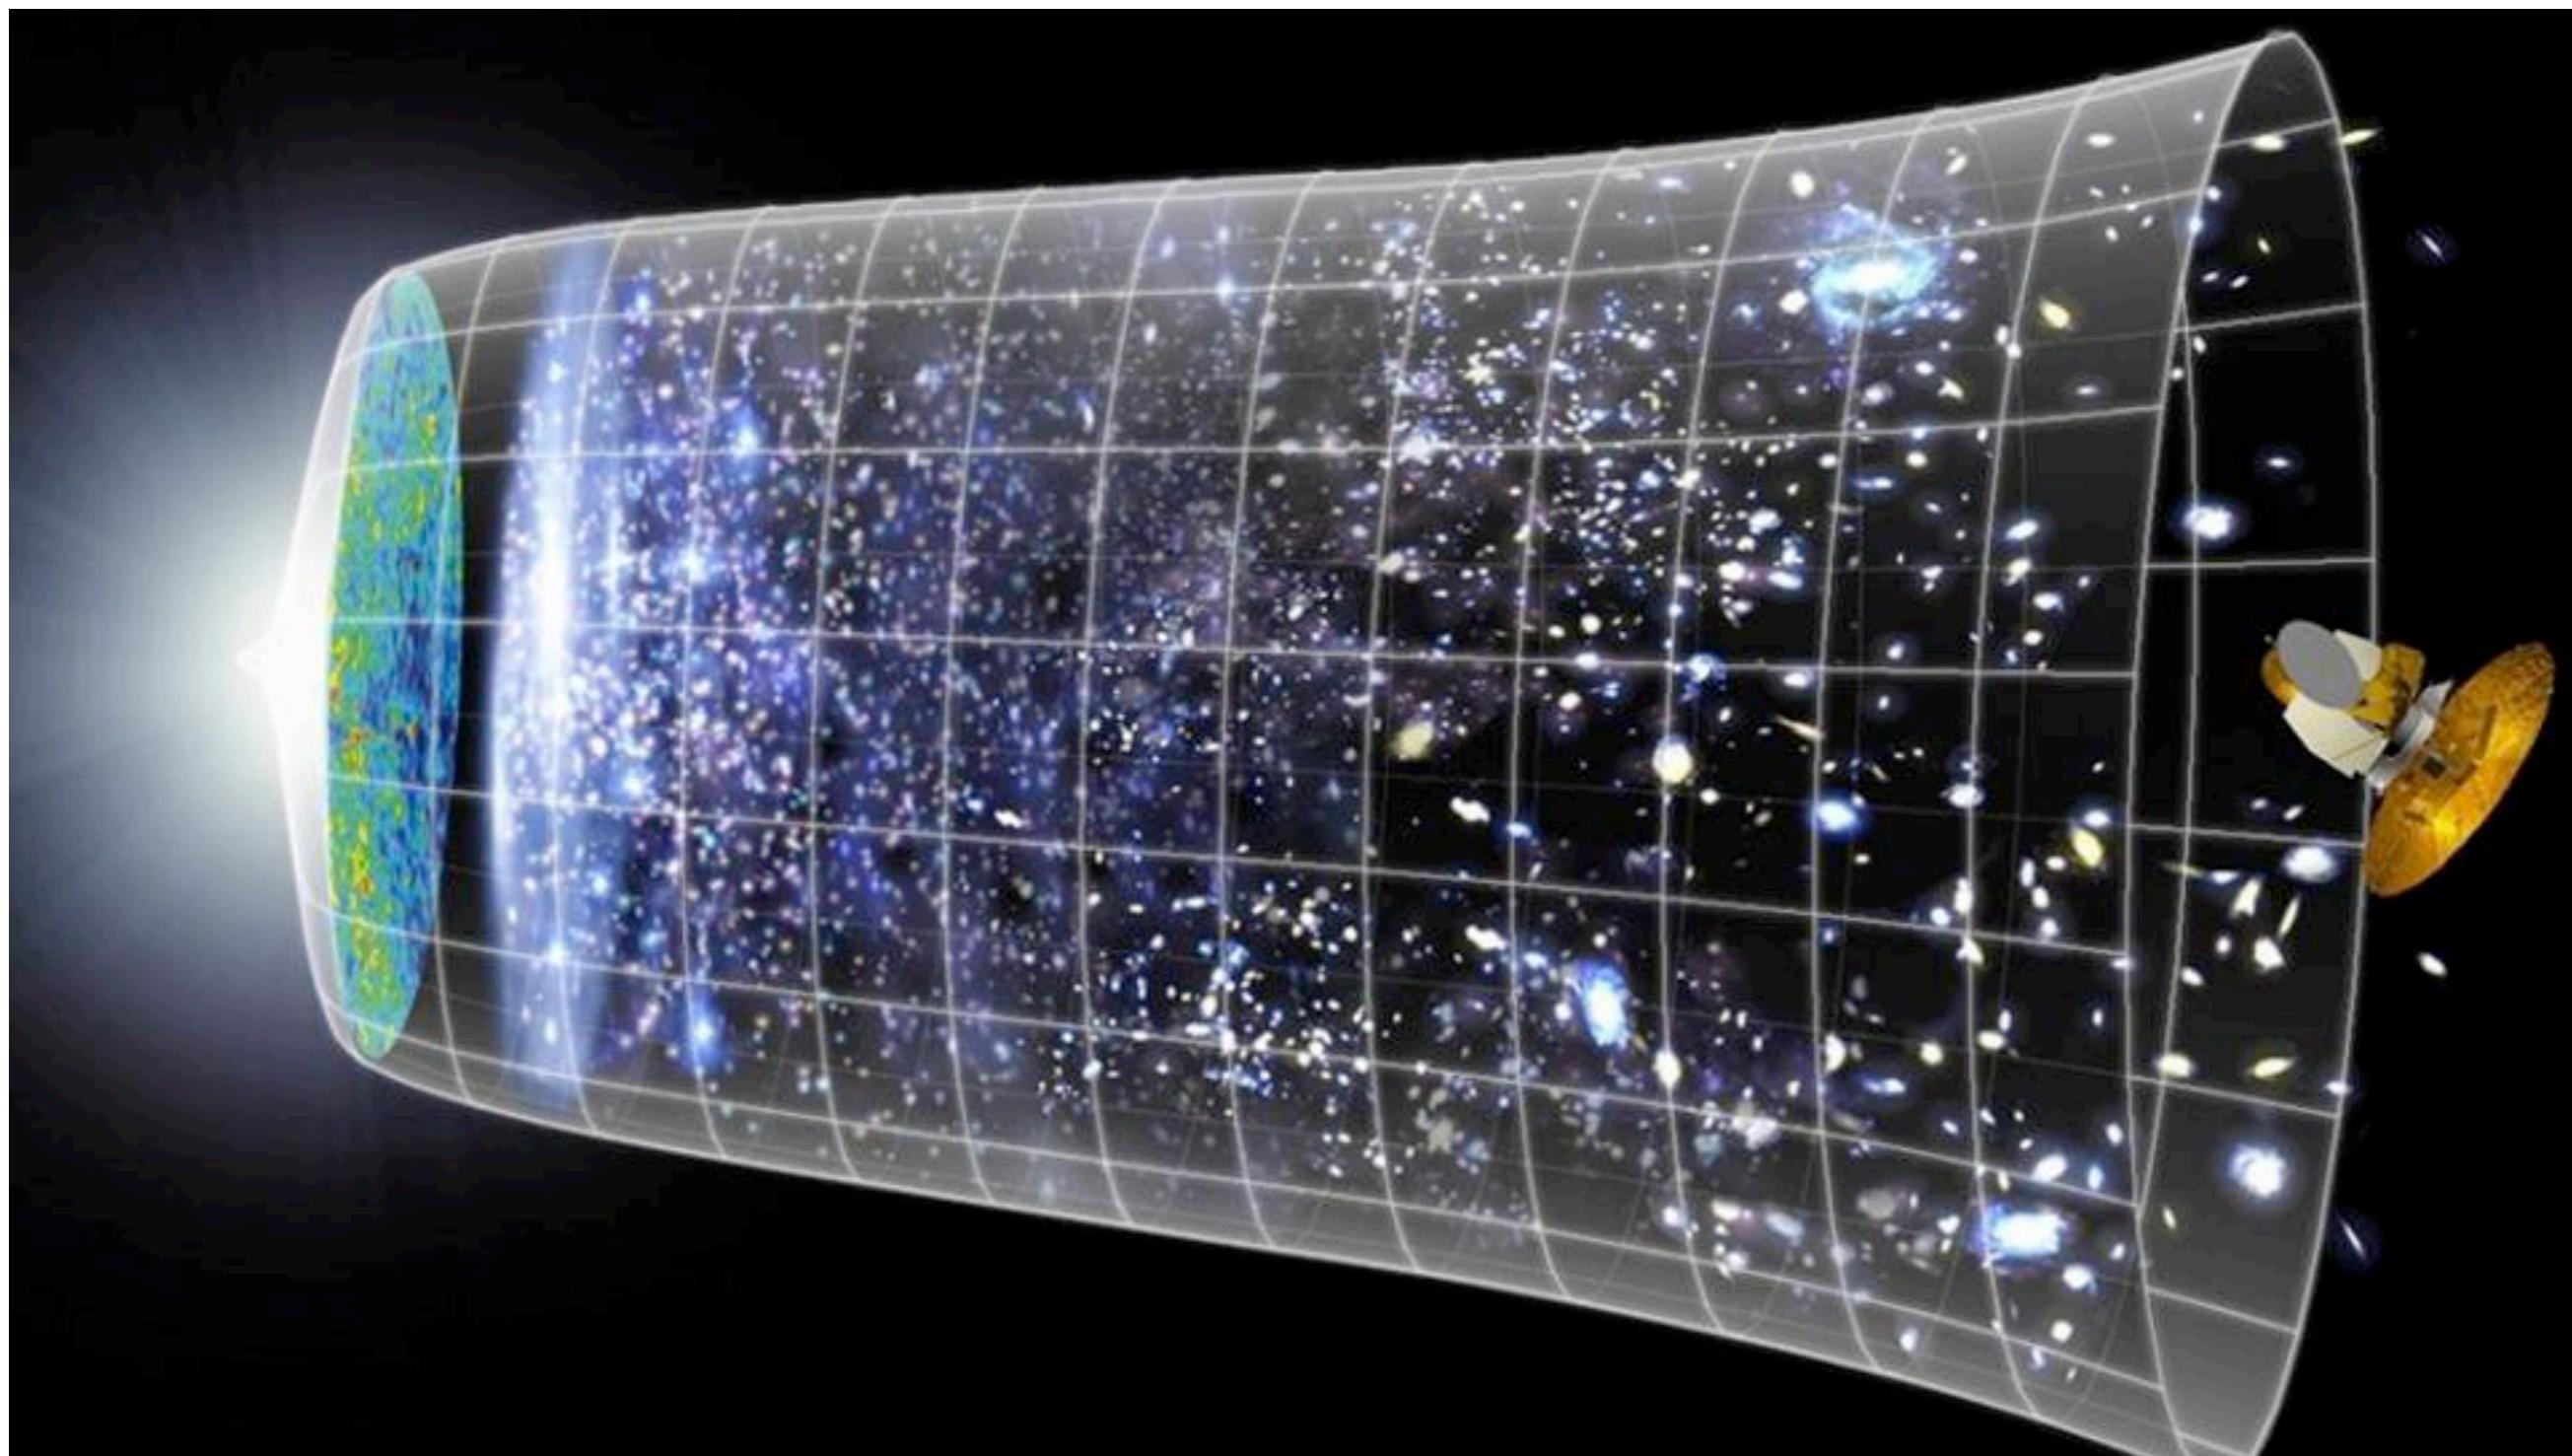
Separación de componentes del fondo cósmico de microondas con redes neuronales

- Fondo cósmico de microondas (o CMB) ¿Qué es?
-





Fondo cósmico de microondas (o CMB)



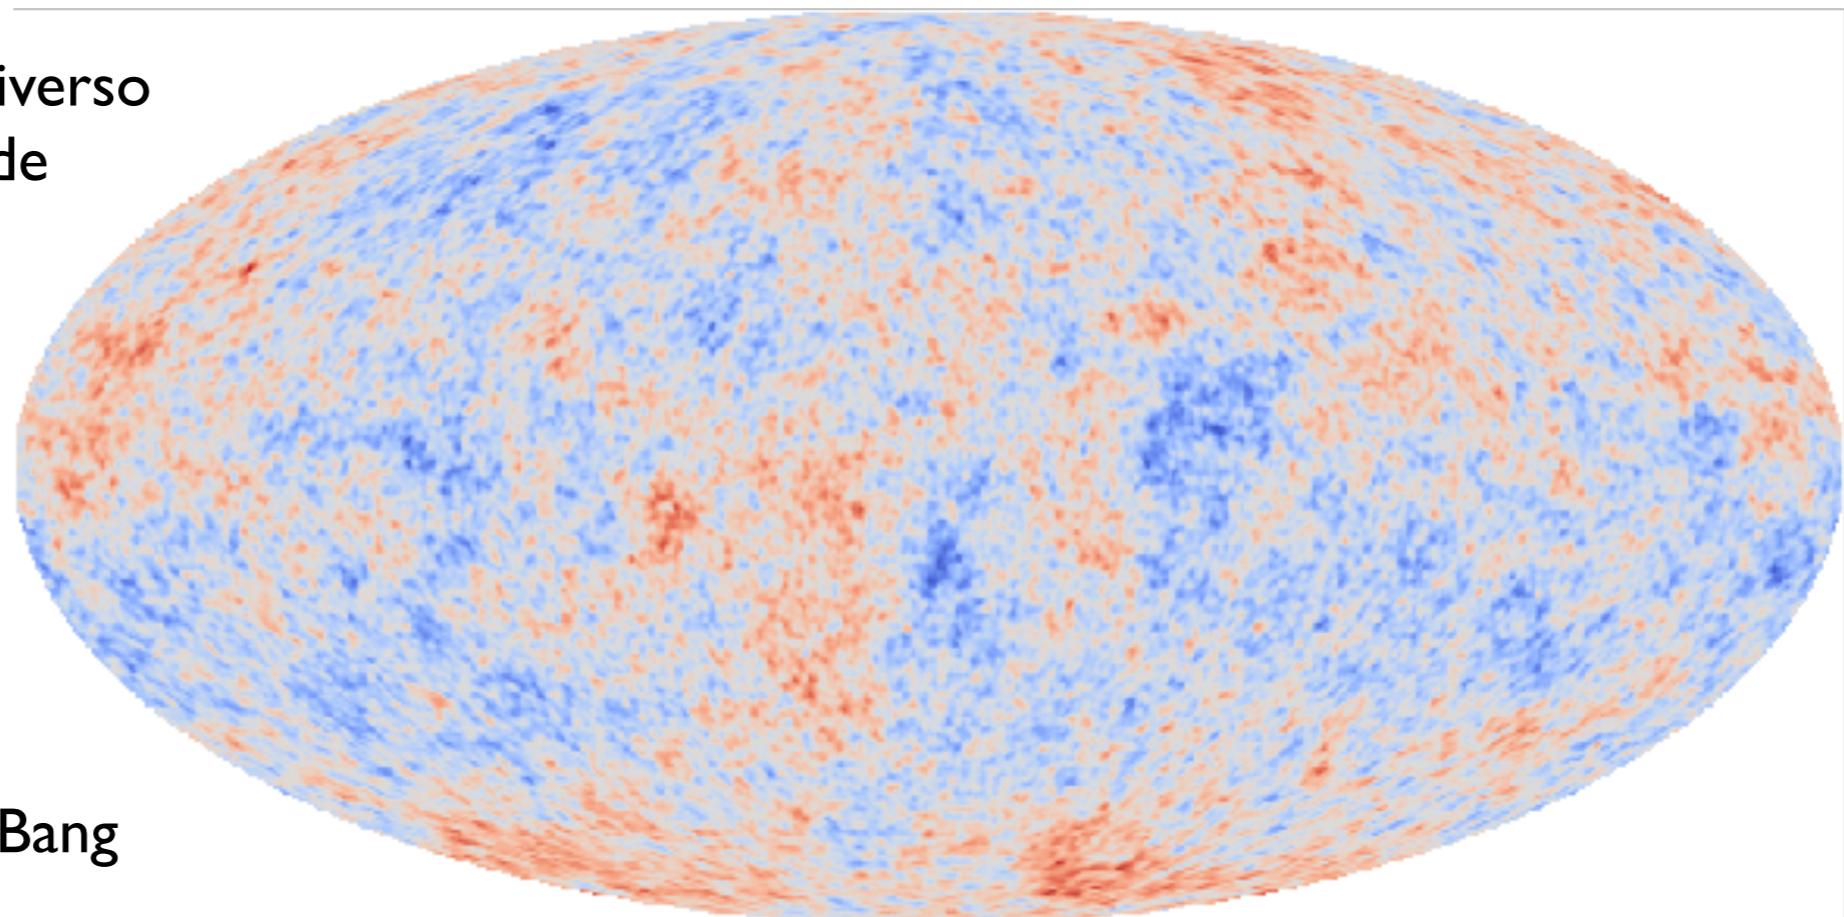
Fondo cósmico de microondas (o CMB)

* Luz que nos llega del Universo primitivo (~300,000 años de edad)

* Temperatura actual del Universo : 3K ~ -270°C

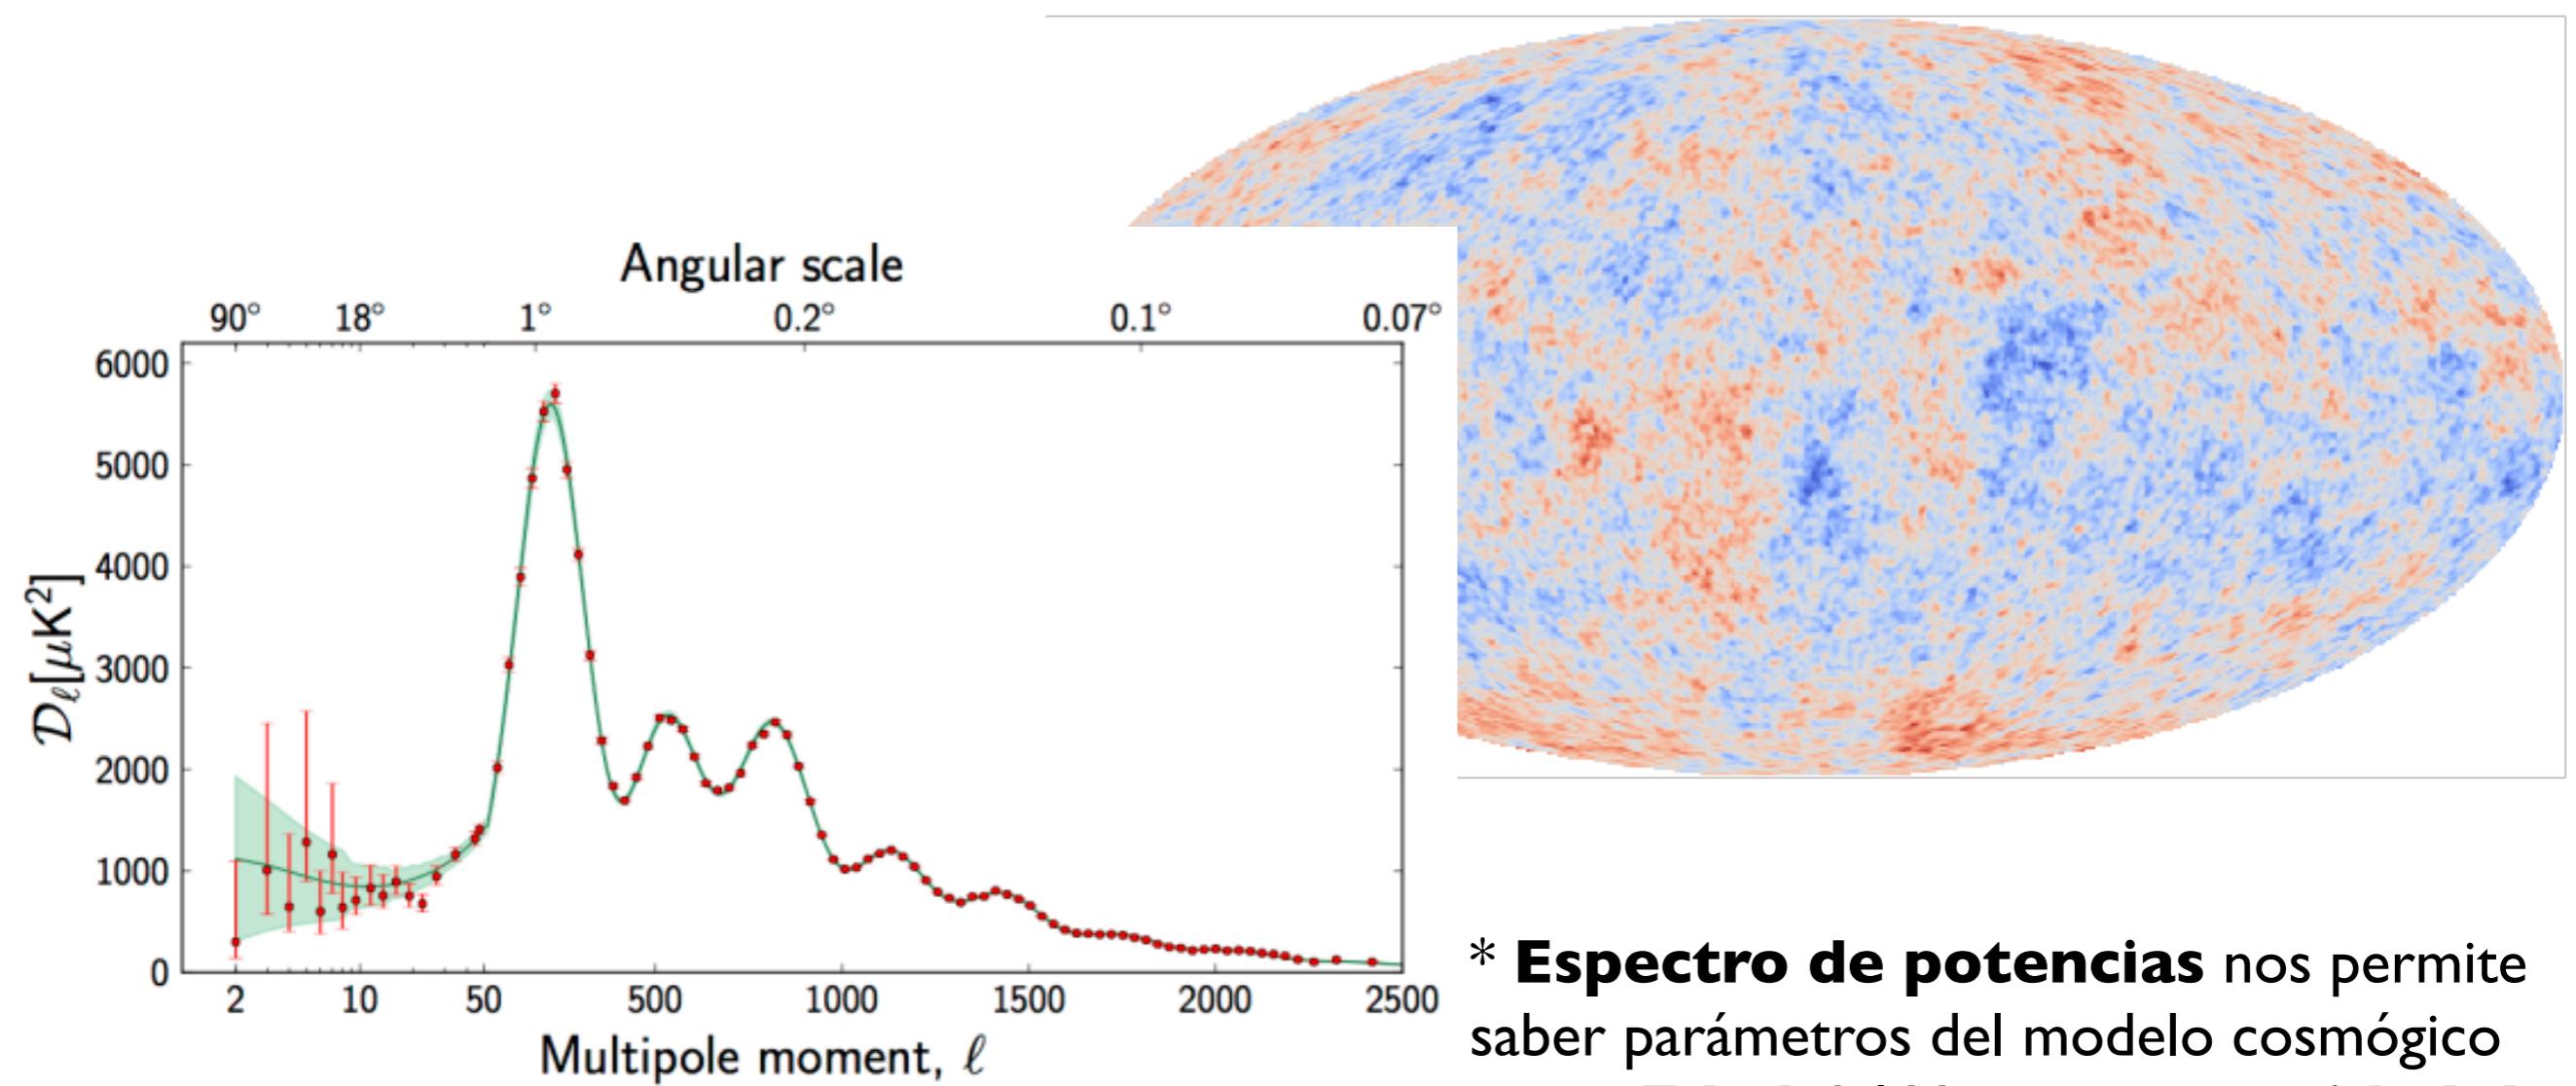
* Primeras estructuras de materia

* Confirmó teoría del Big Bang



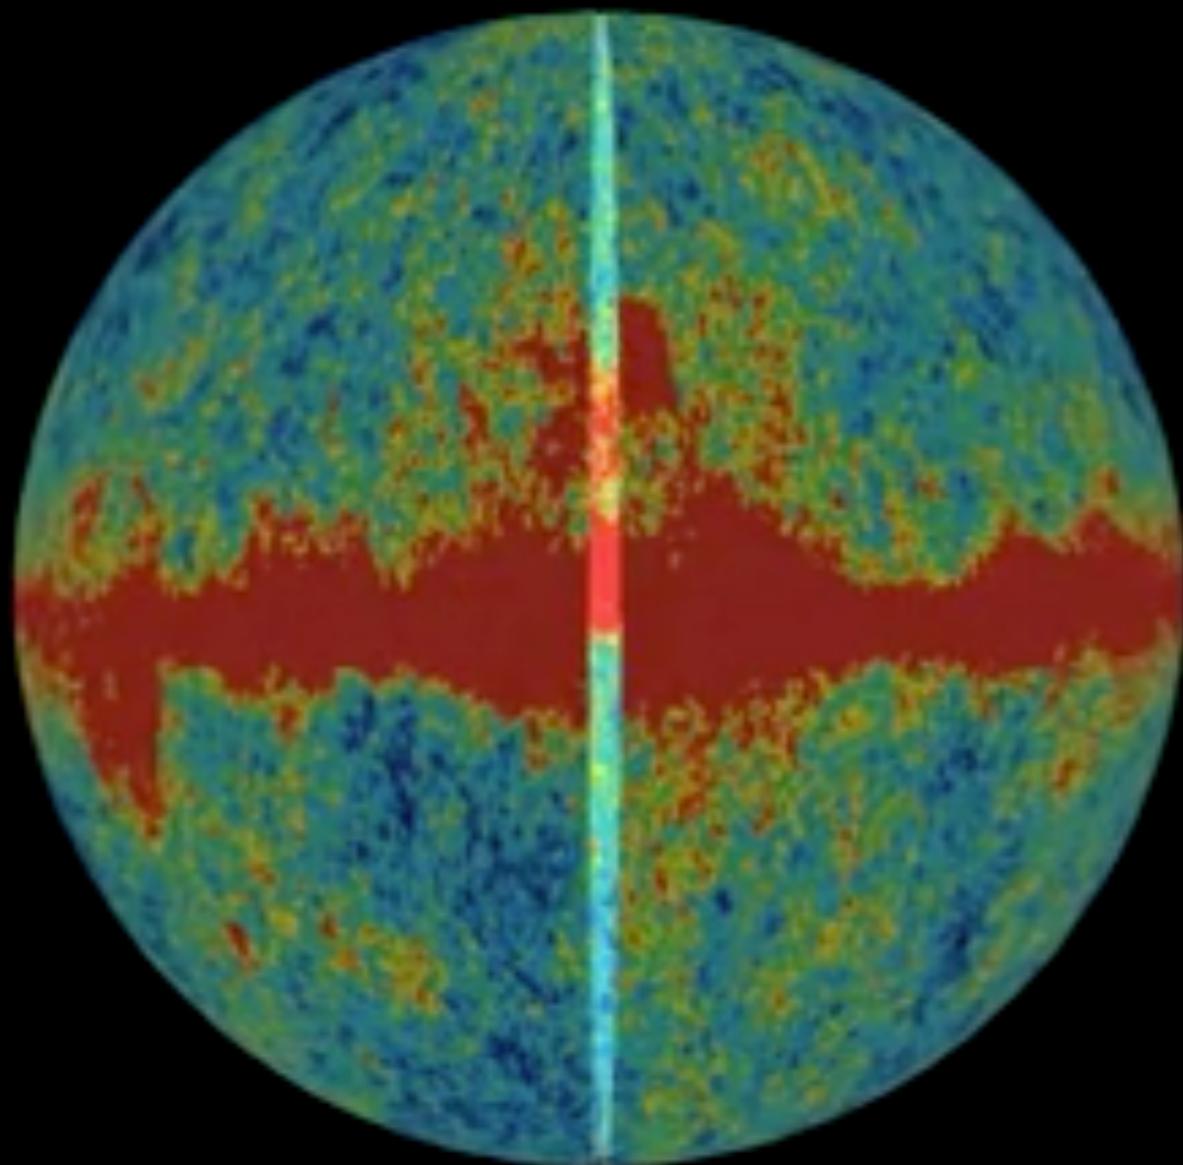
Mapa de temperatura del CMB

Fondo cósmico de microondas (o CMB)

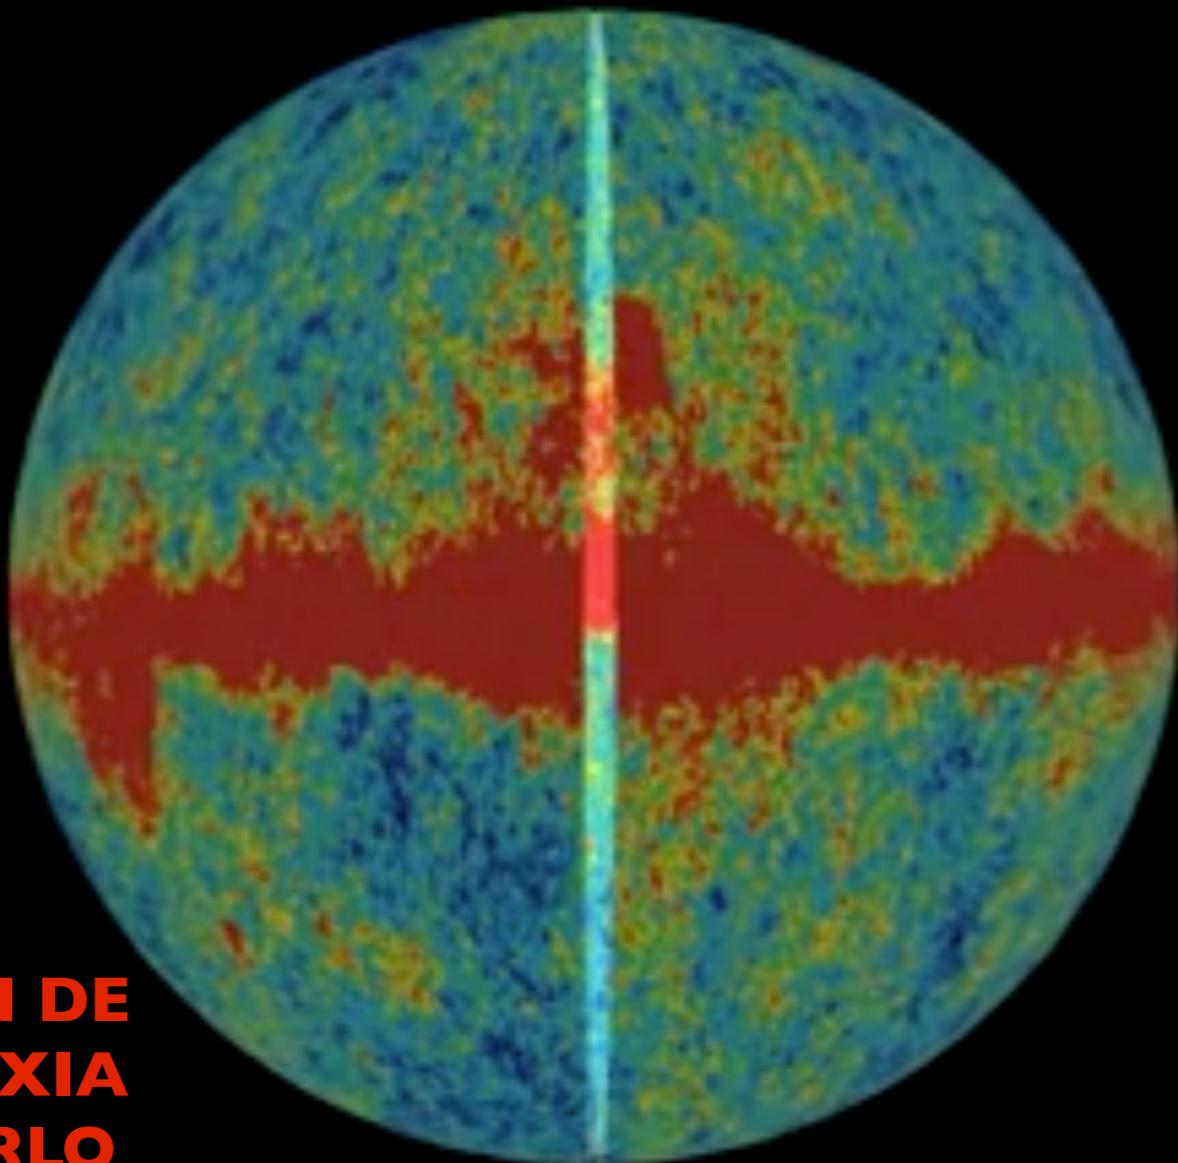


* **Espectro de potencias** nos permite saber parámetros del modelo cosmológico como: **Edad** del Universo, **velocidad de expansión**, cantidad total de **materia**, % de **materia oscura**, **energía oscura**, ...

Fondo cósmico de microondas (o CMB)



Fondo cósmico de microondas (o CMB)



**¡¡ LA RADIACION DE
NUESTRA GALAXIA
NOS IMPIDE VERLO
BIEN !!**

Fondo cósmico de microondas

- Recibimos emisiones de nuestra propia galaxia que nos impiden ver el CMB.
- Si ponemos detectores de baja frecuencia (< 40GHz) domina la emisión sincrotrón, free-free y AME.
- Si ponemos detectores de alta frecuencia (>150 GHz) nuestros mapas están dominados por el polvo térmico.
- A frecuencias intermedias, vemos CMB, pero SOLO a altas latitudes.

Separación de componentes del fondo cósmico de microondas con redes neuronales

- Separación de componentes del CMB
-

Separación de componentes

¿Cómo podemos separar el fondo cósmico de microondas de todo lo demás?

Tenemos la gran ventaja que los *foregrounds* y el CMB tienen una dependencia frecuencial distinta.

* El CMB es constante en todas las frecuencias porque es una emisión de naturaleza térmica que sigue la ley de Planck:

$$A = A_{cmb}$$

* El sincrotrón se pueden aproximar como una ley de potencias

$$A = A_s \left(\frac{\nu}{\nu_o} \right)^{-\beta}$$

* El polvo emite como un cuerpo negro modificado

$$A = A_d \left(\frac{\nu}{\nu_o} \right)^{\alpha+1} \frac{e^{x_o} - 1}{e^x - 1}$$

Separación de componentes

¿Cómo podemos separar el fondo cósmico de microondas de todo lo demás?

Tenemos la gran ventaja que los *foregrounds* y el CMB tienen una dependencia frecuencial distinta.

* El CMB es constante en todas las frecuencias porque es una emisión de naturaleza térmica que sigue la ley de Planck:

$$A = A_{cmb}$$

* El sincrotrón se pueden aproximar como una ley de potencias

$$A = A_s \left(\frac{\nu}{\nu_o} \right)^{-\beta}$$

dominan a energías bajas

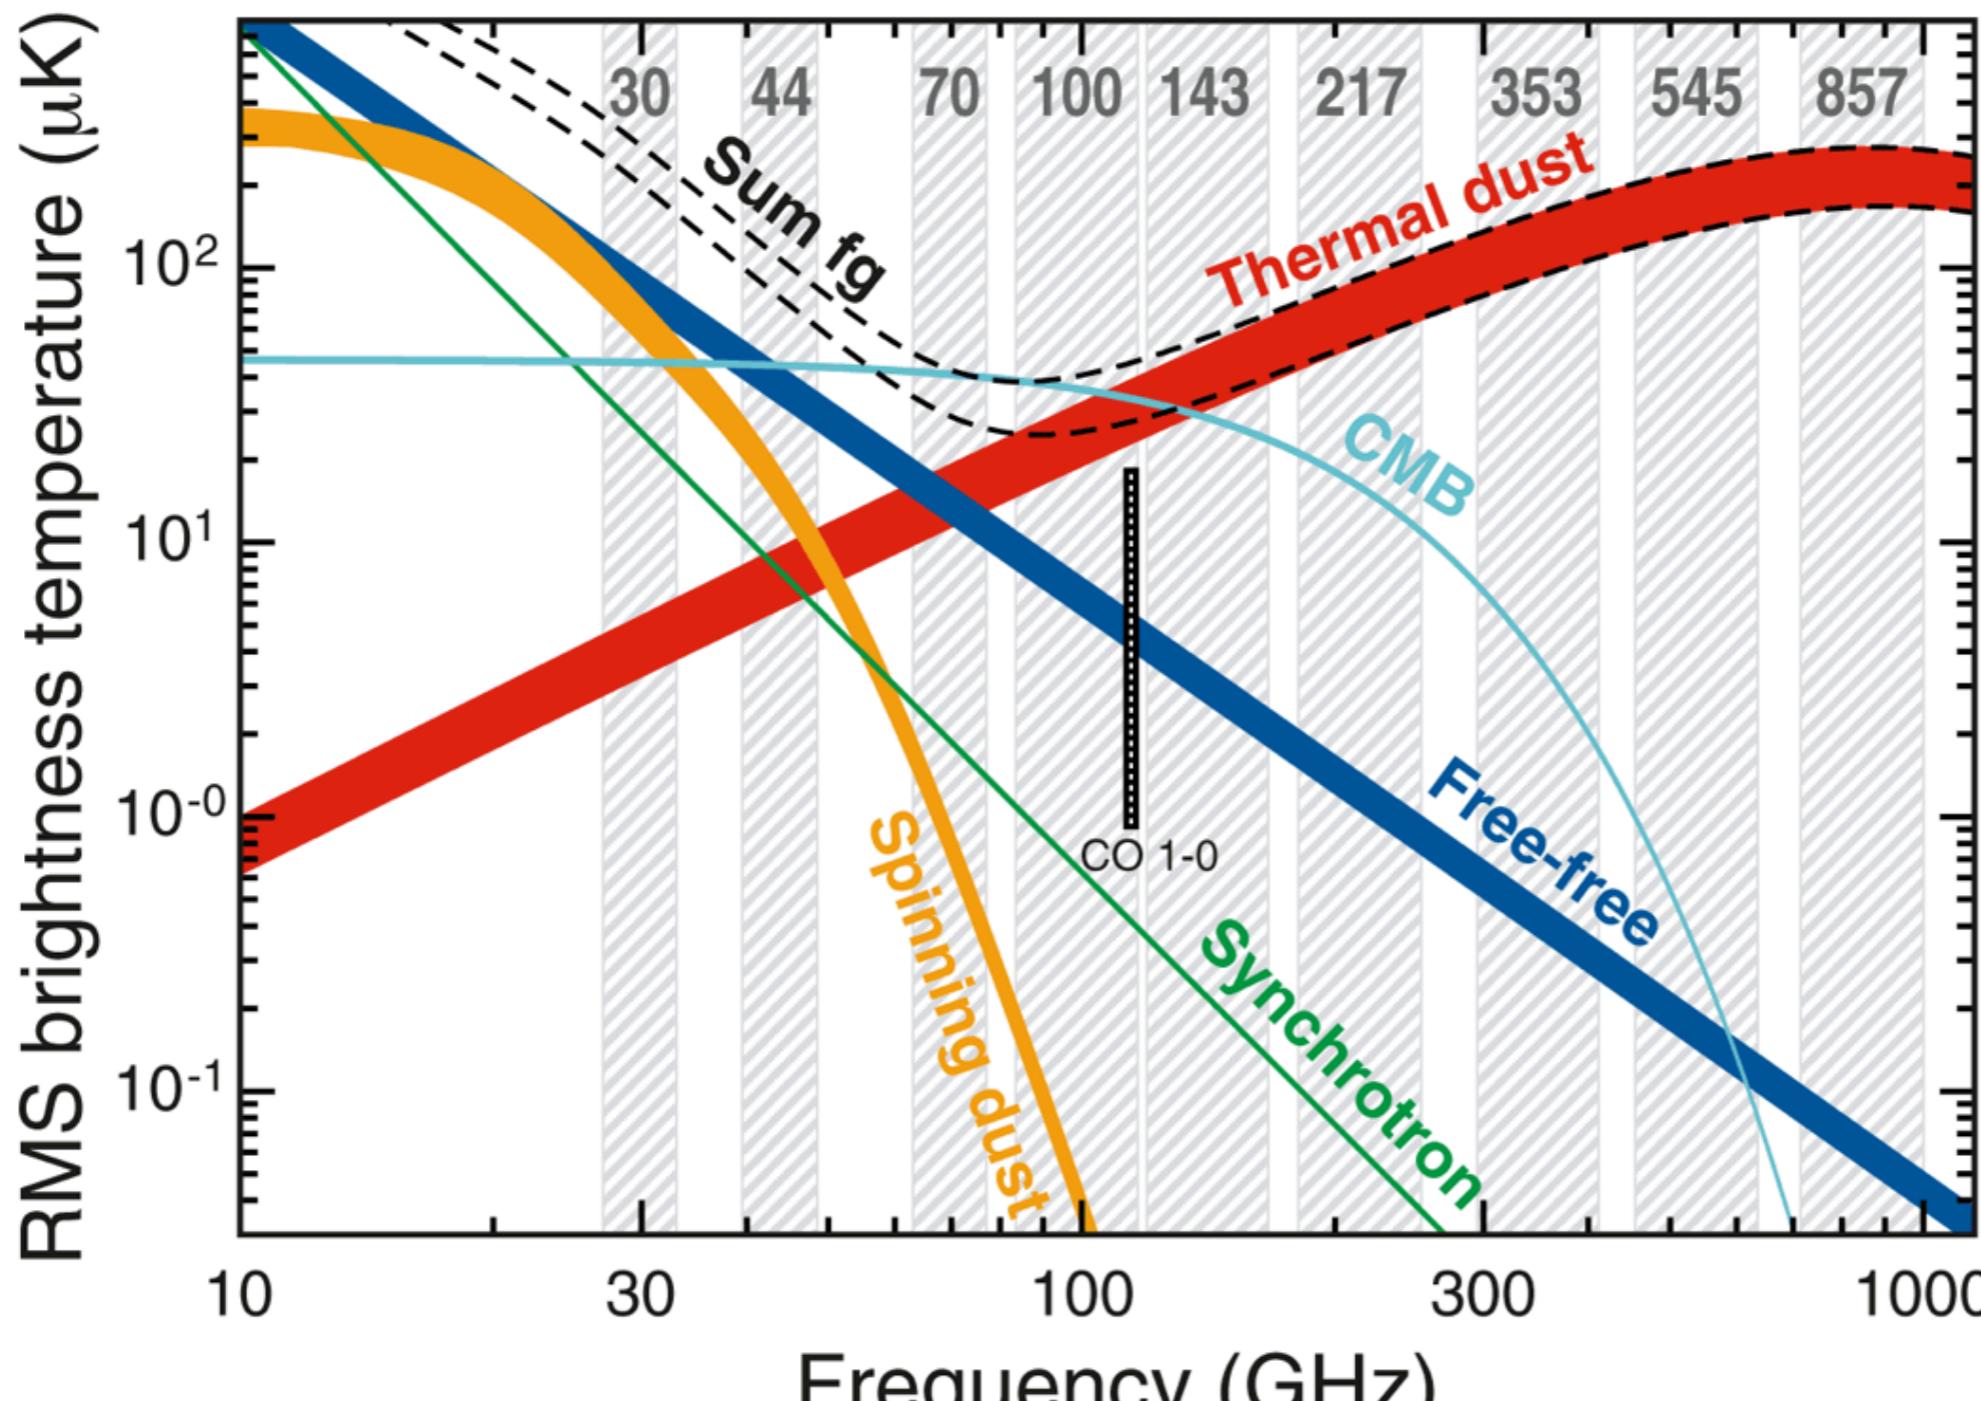
* El polvo emite como un cuerpo negro modificado

dominan a energías altas

$$A = A_d \left(\frac{\nu}{\nu_o} \right)^{\alpha+1} \frac{e^{x_o} - 1}{e^x - 1}$$

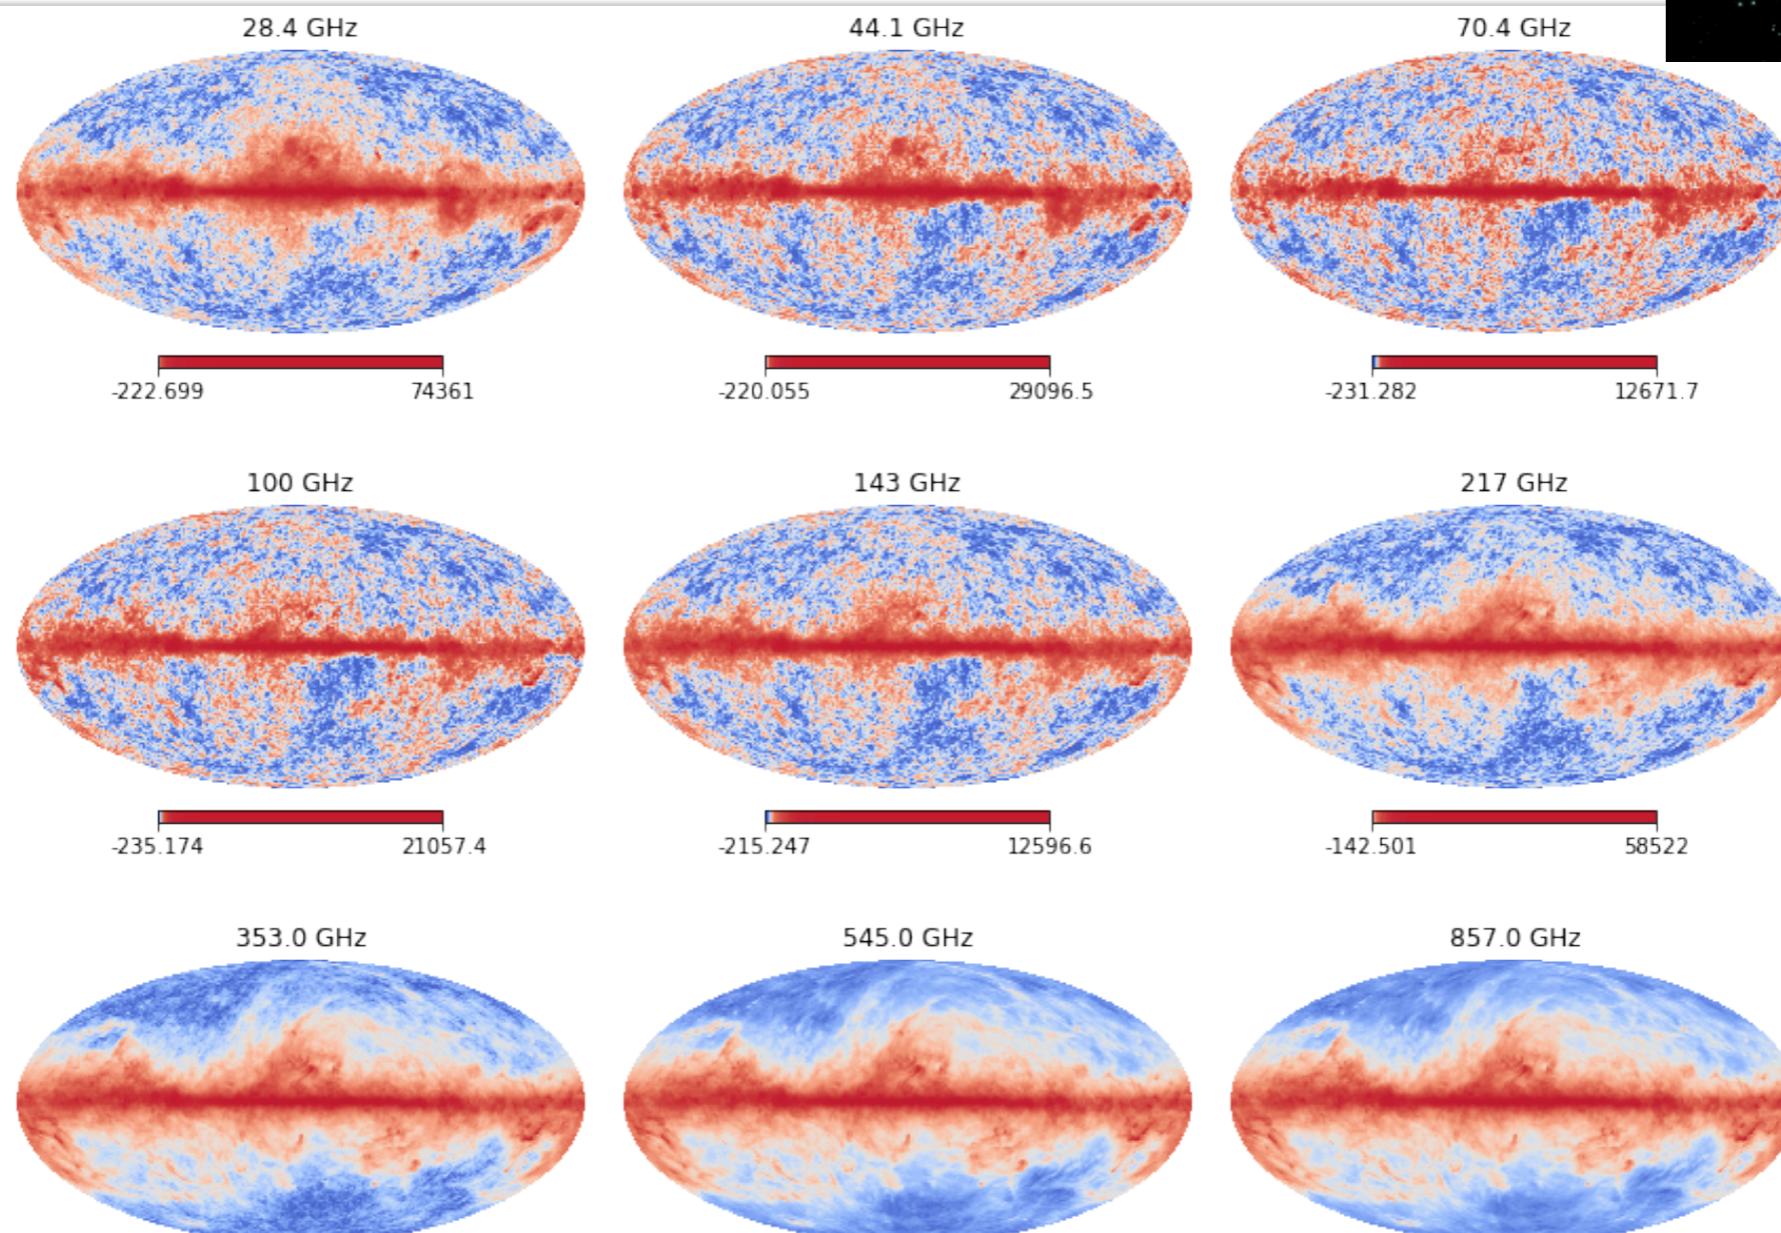
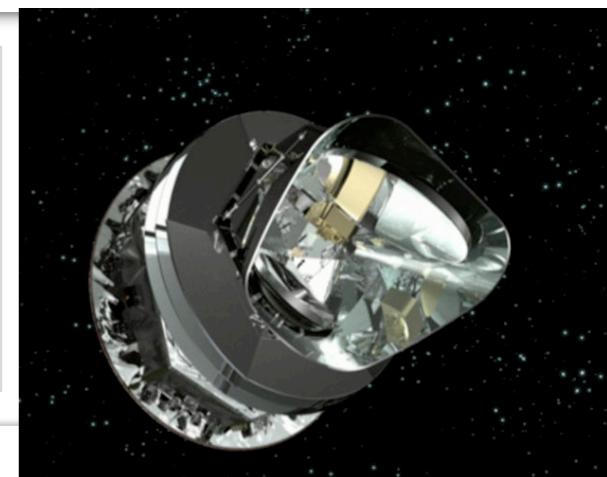
Separación de componentes

¿Cómo podemos separar el fondo cósmico de microondas de todo lo demás?



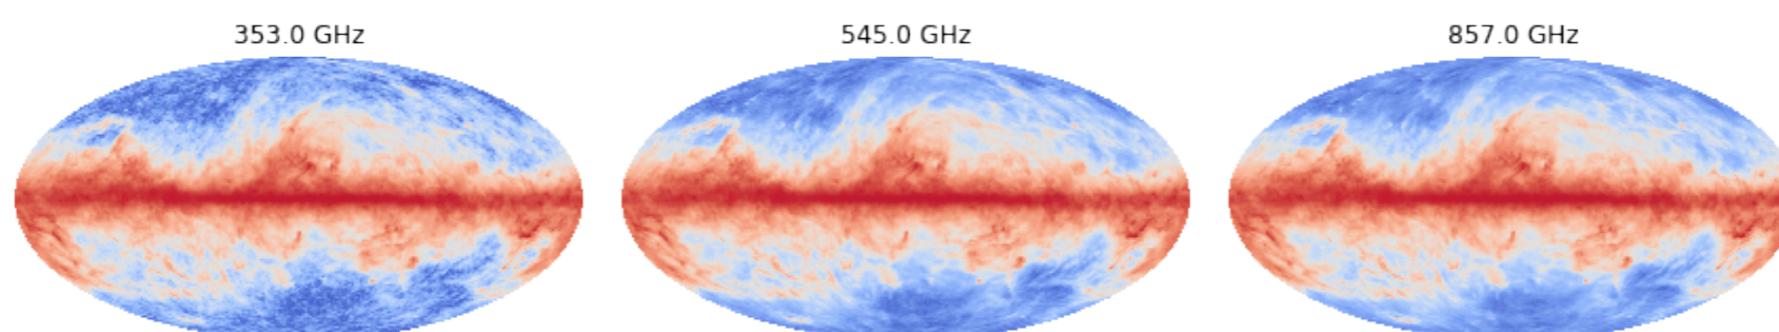
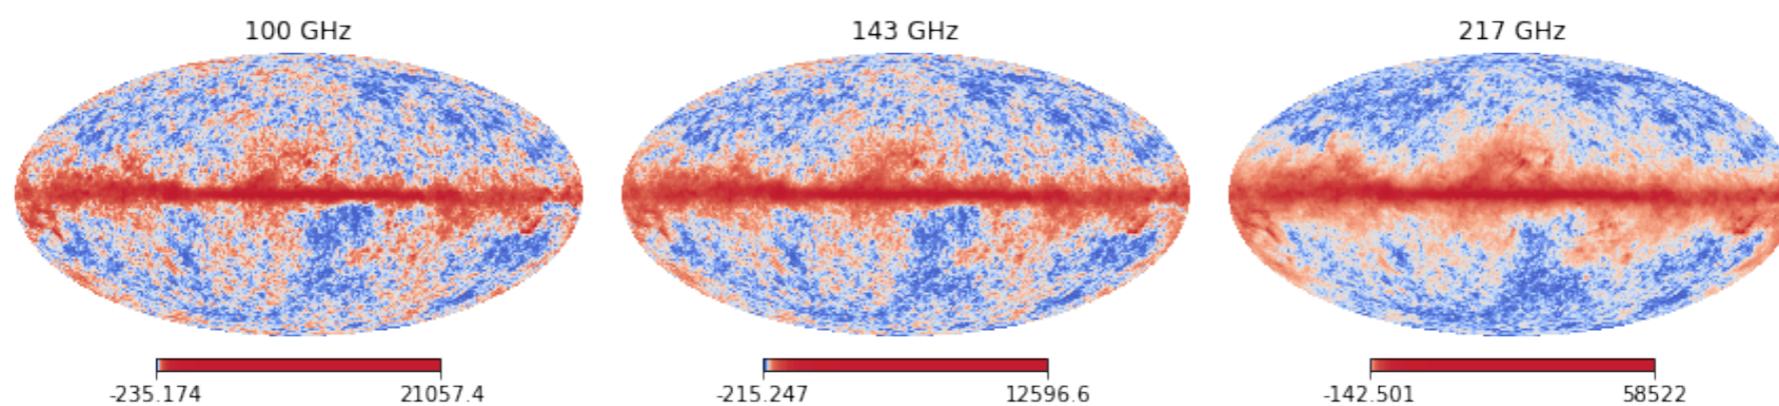
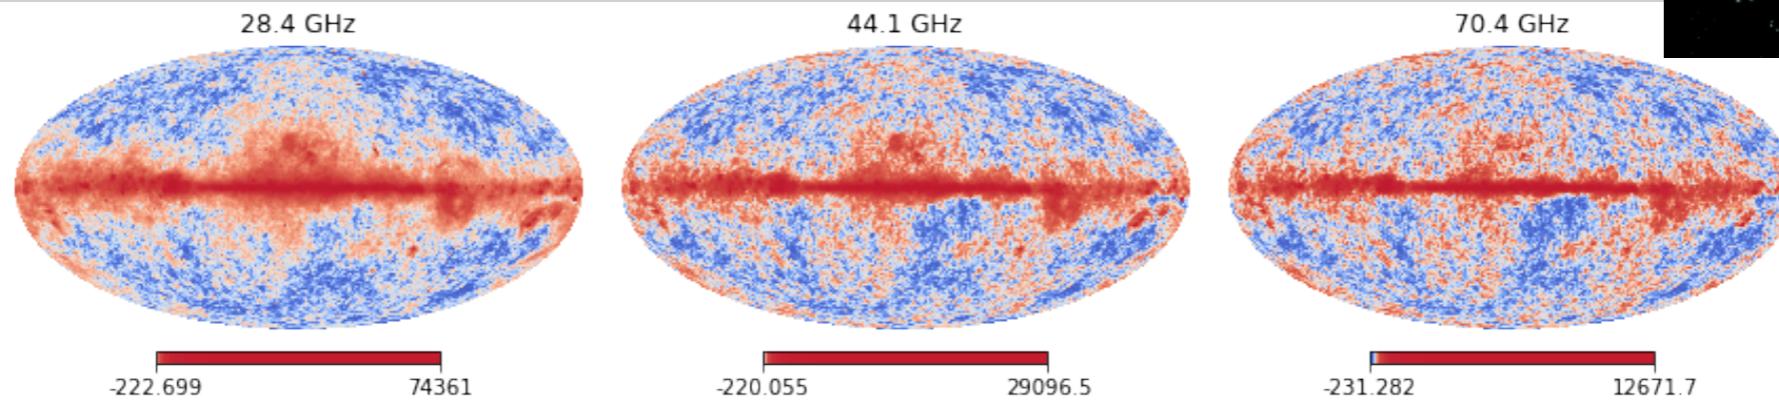
Separación de componentes

Por eso es interesante observar el cielo a varias frecuencias. El satélite Planck nos da 9 mapas frecuenciales



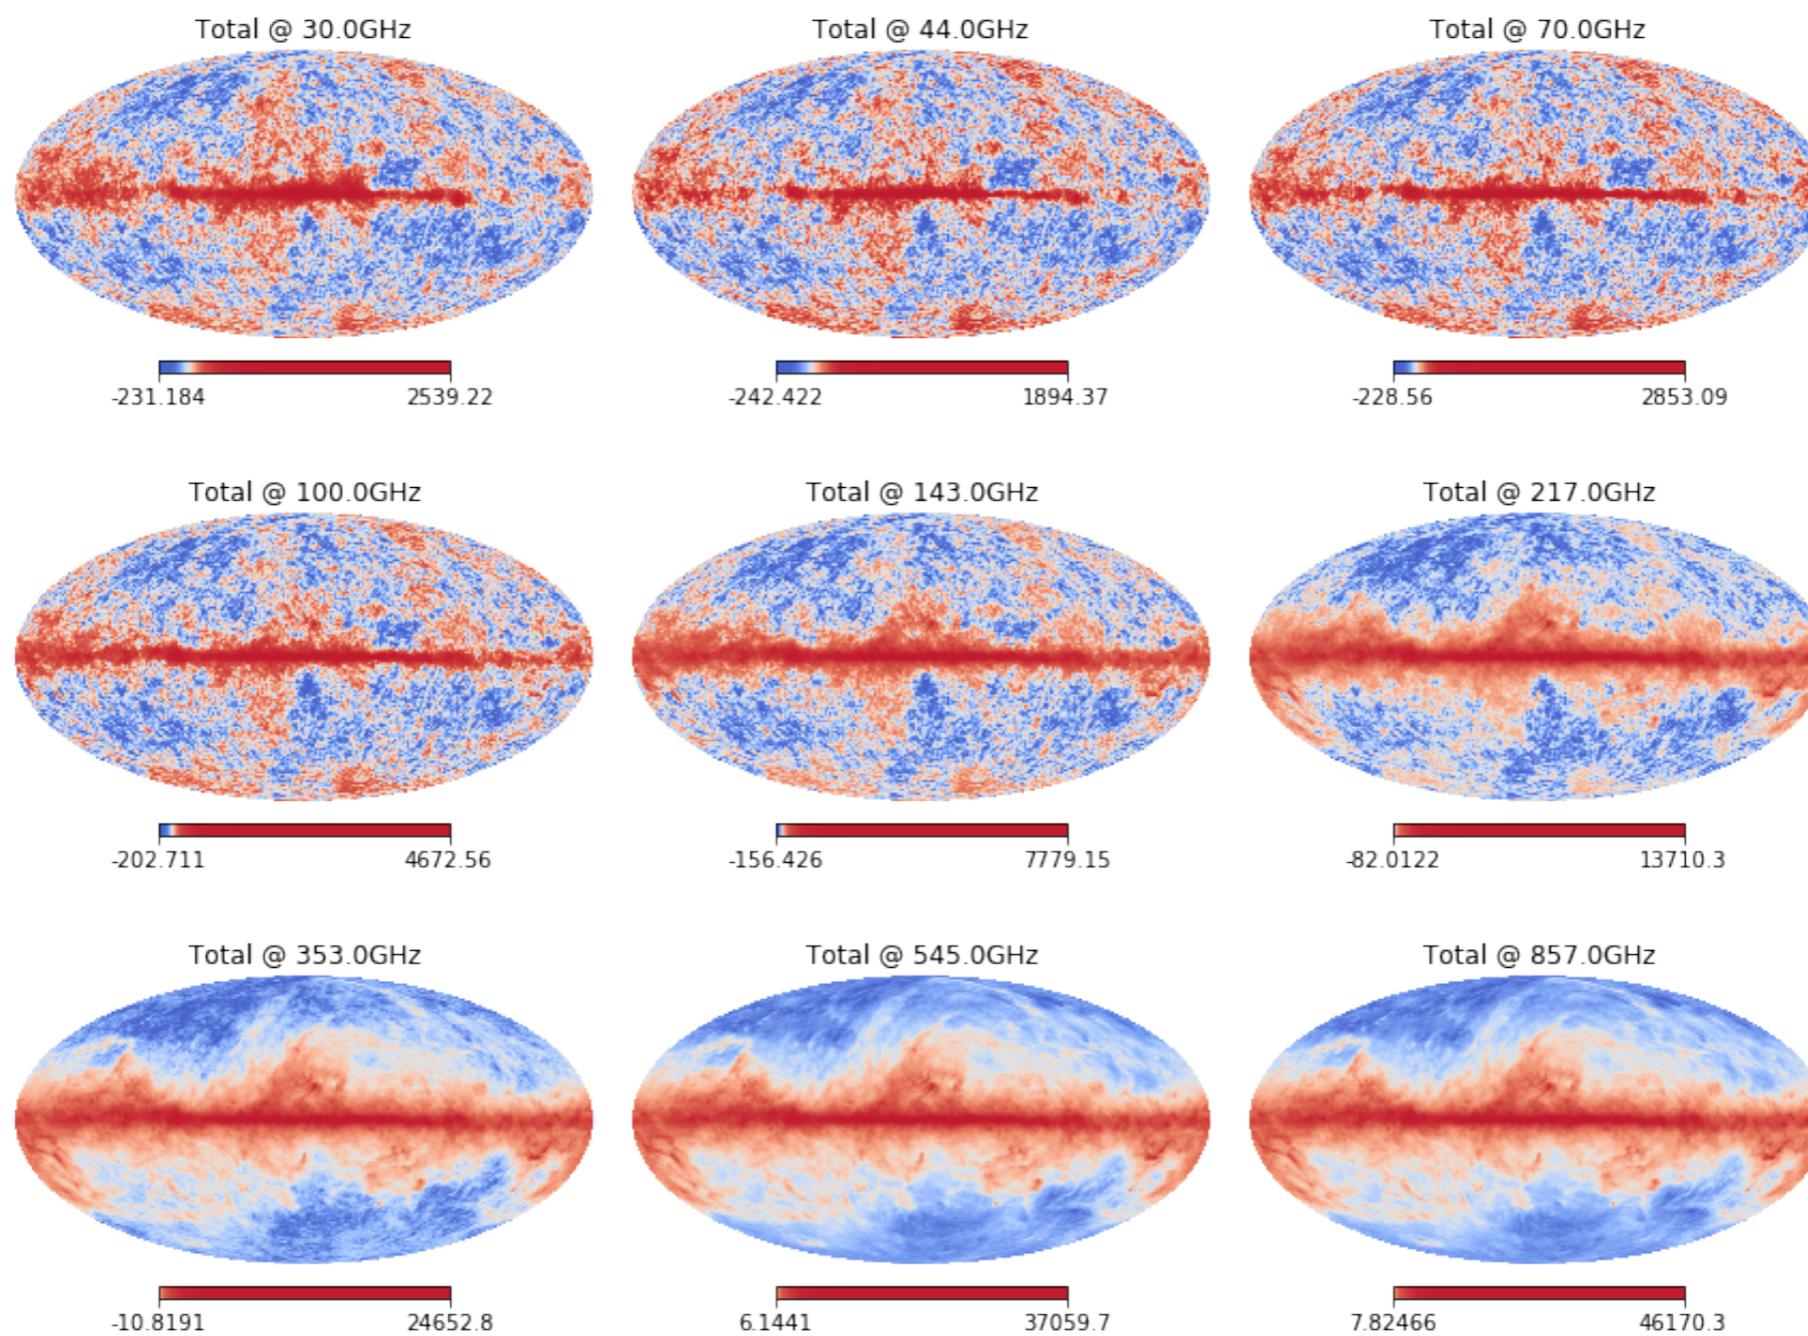
Separación de componentes

Por eso es interesante observar el cielo a varias frecuencias. El satélite Planck nos da 9 mapas frecuenciales



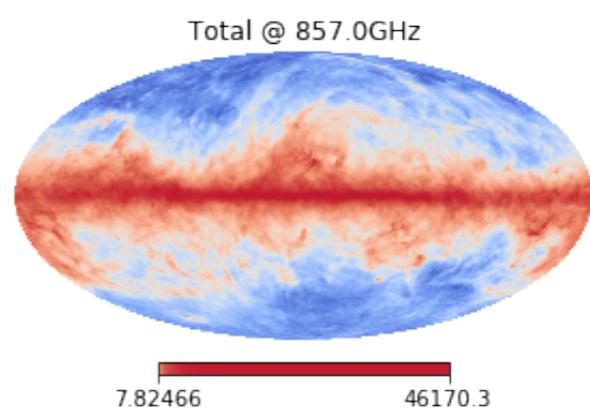
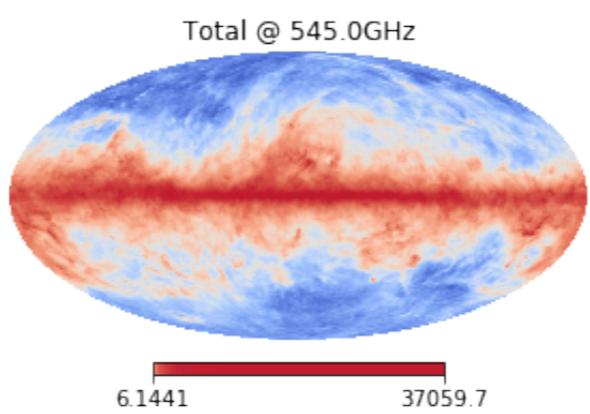
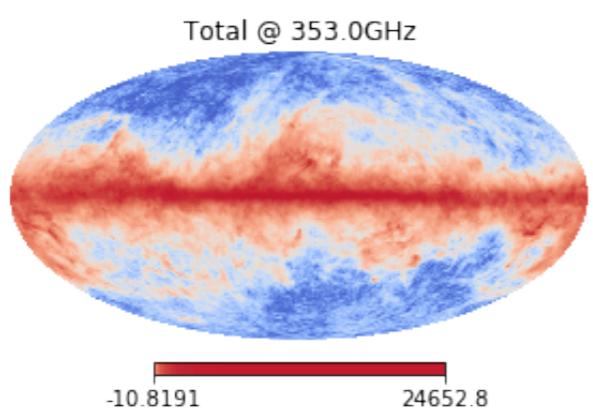
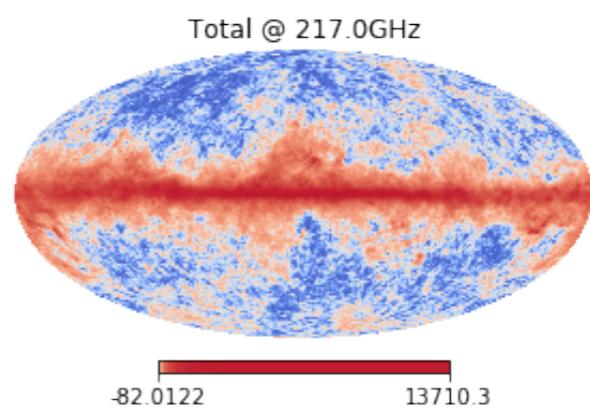
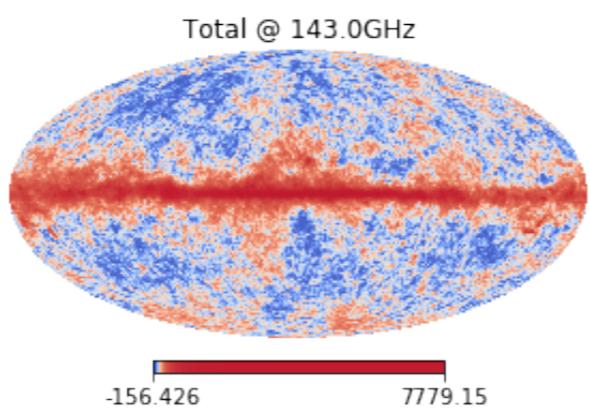
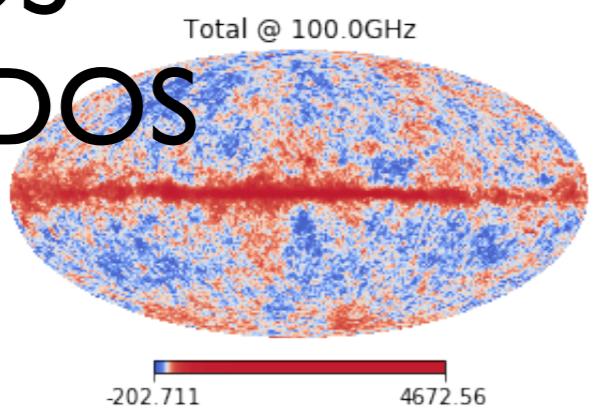
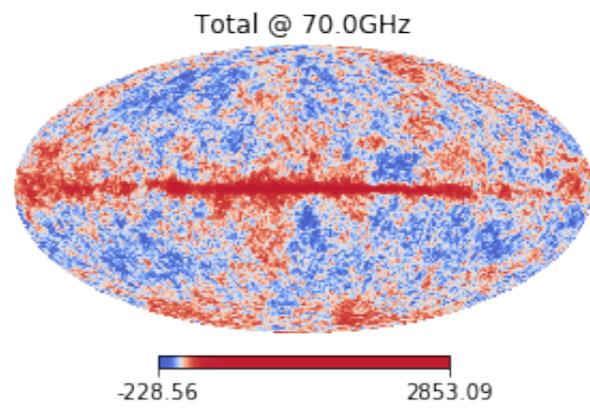
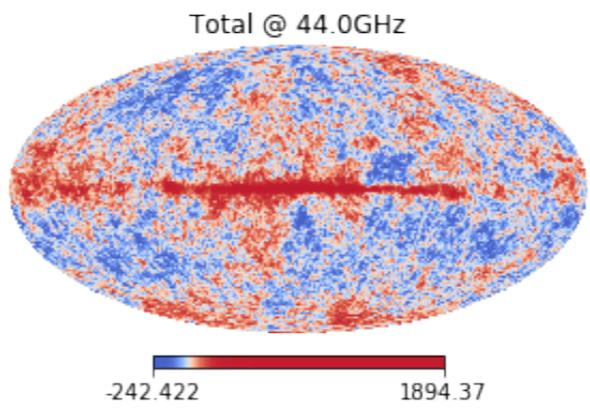
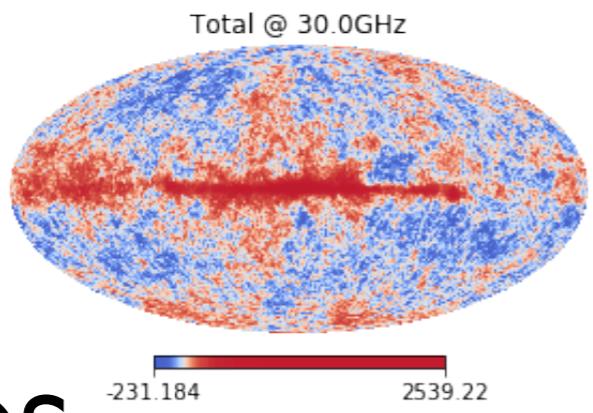
DATOS
REALES

Si lo miramos con una simulación sencilla de CMB + sincrotrón + polvo + **ruido**



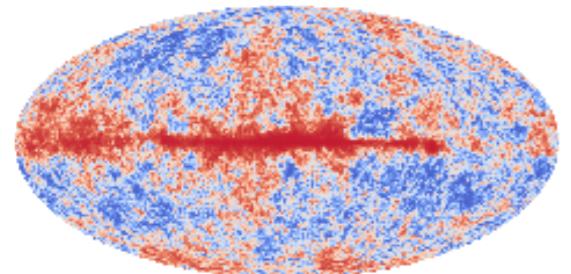
Si lo miramos con una simulación sencilla de
CMB + sincrotrón + polvo + **ruido**

DATOS
SIMULADOS



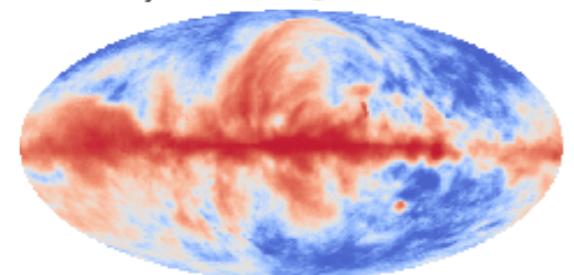
descomposicion datos simulados

Total @ 30.0GHz



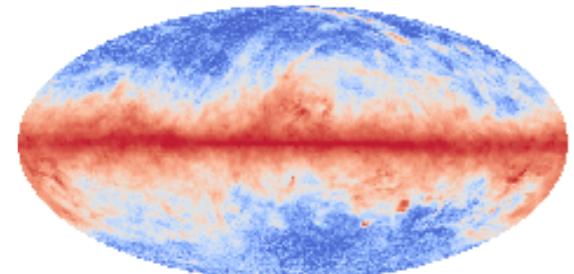
-227.551 2539.04

Synchrotron @ 30.0GHz



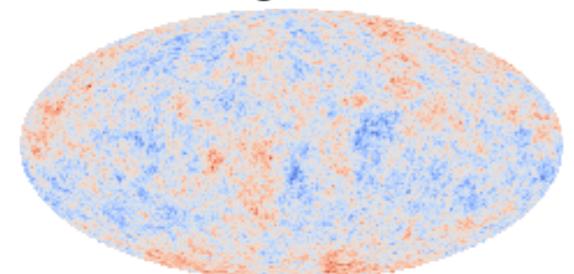
10.0932 1870.72

Dust @ 30.0GHz



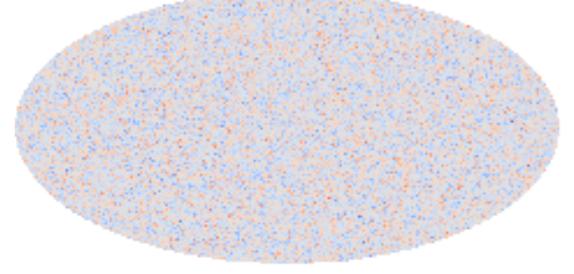
0.0165484 401.678

Cmb @ 30.0GHz

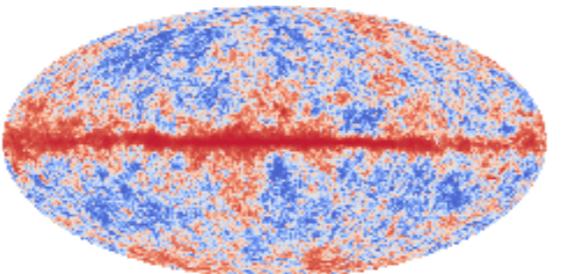


-282.797 305.743

Noise @ 30.0GHz

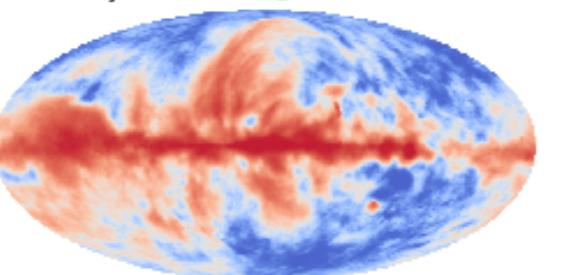


Total @ 100.0GHz



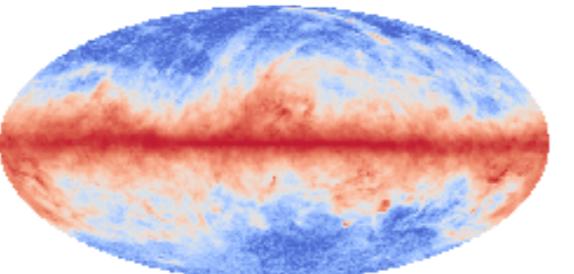
-201.713 4671.79

Synchrotron @ 100.0GHz



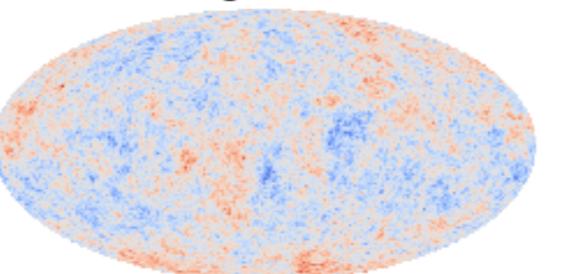
0.227816 52.5658

Dust @ 100.0GHz



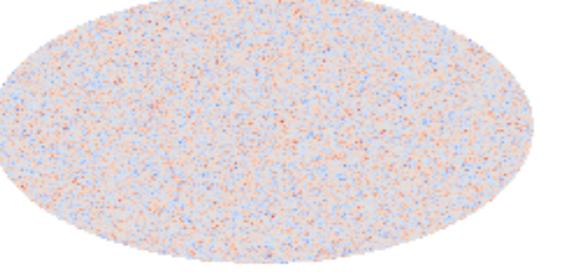
0.28838 2645.31

Cmb @ 100.0GHz

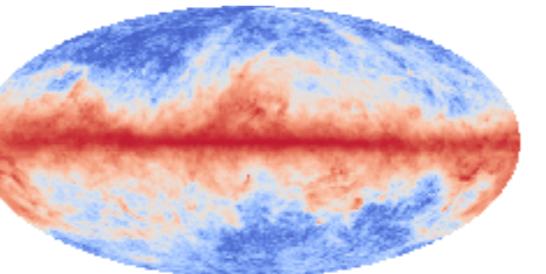


-224.957 243.21

Noise @ 100.0GHz

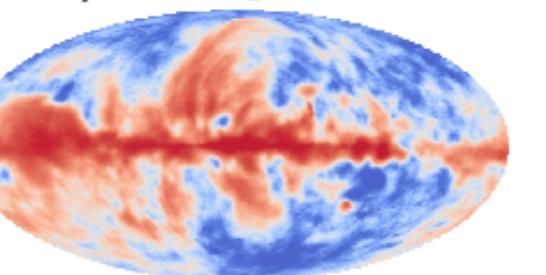


Total @ 353.0GHz



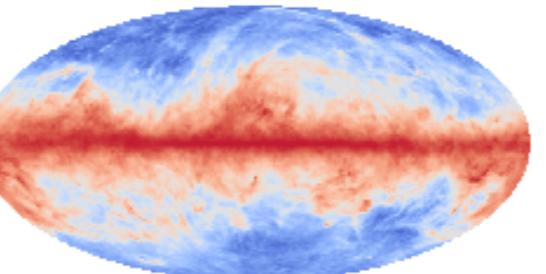
-10.3958 24652.7

Synchrotron @ 353.0GHz



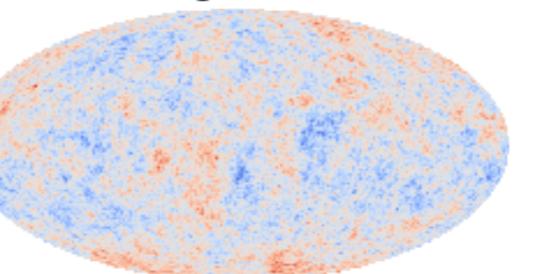
0.00429285 1.25193

Dust @ 353.0GHz



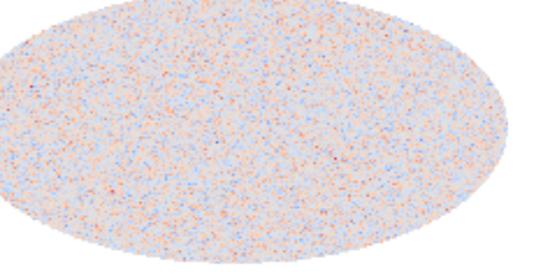
4.18076 24654.3

Cmb @ 353.0GHz

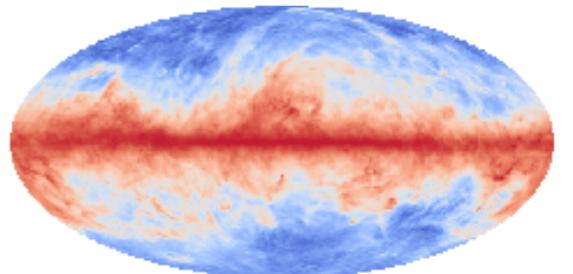


-22.4272 24.2469

Noise @ 353.0GHz

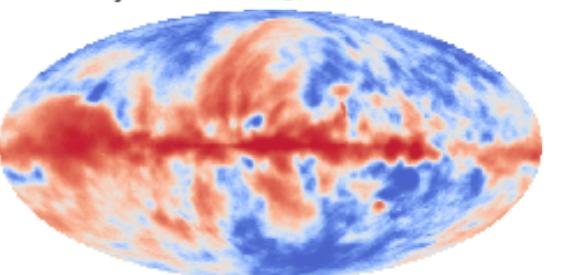


Total @ 857.0GHz



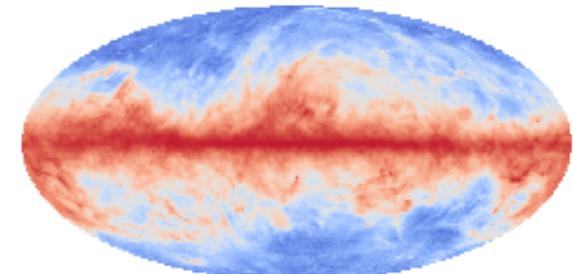
7.82966 46170.3

Synchrotron @ 857.0GHz



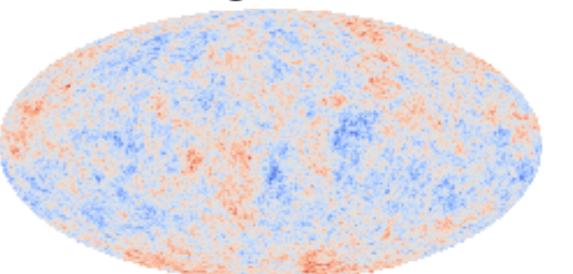
0.000262909 0.0949842

Dust @ 857.0GHz



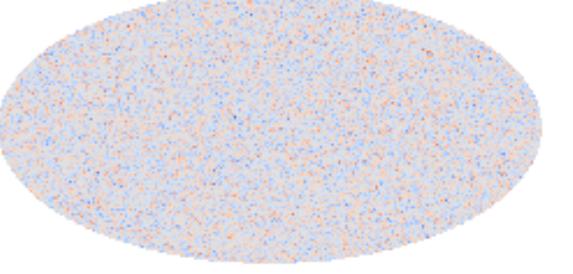
6.52631 74377.6

Cmb @ 857.0GHz

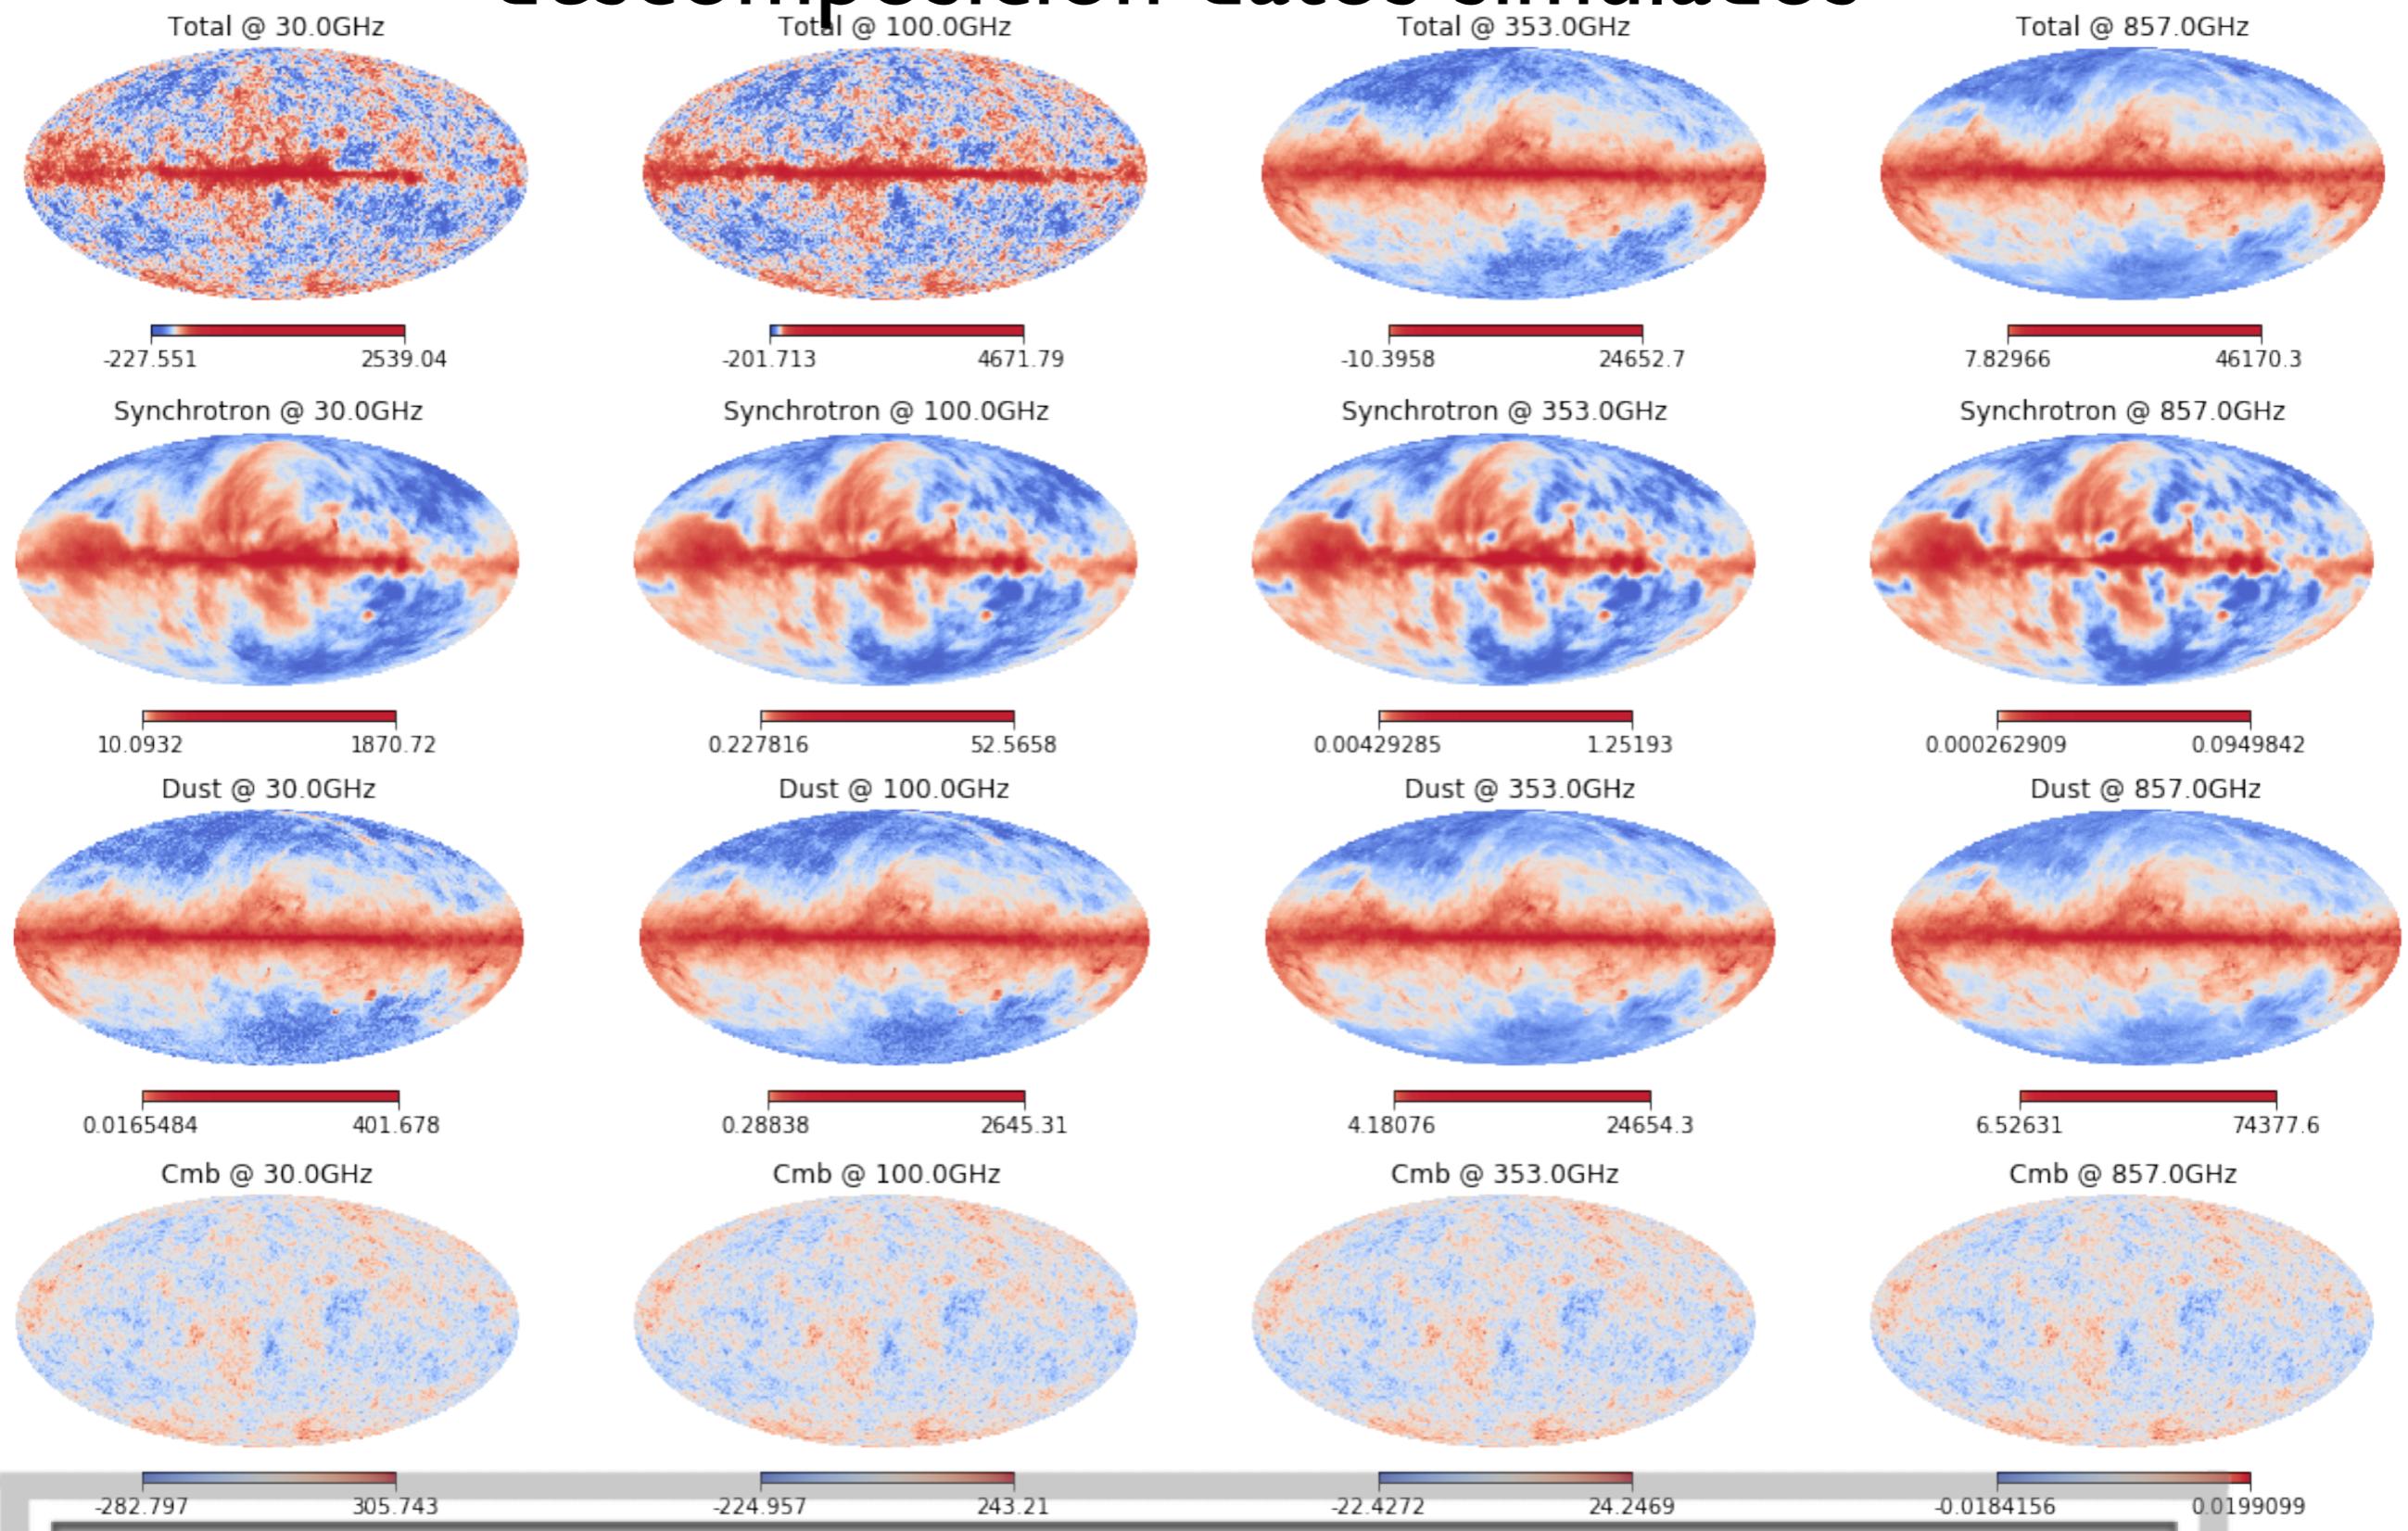


-0.0184156 0.0199099

Noise @ 857.0GHz



descomposición datos simulados



Al final, queremos ser capaces de hacer esta separación con los datos de verdad

Separación de componentes

- Hay dos tipos de métodos:
 - CIEGOS (e.g. ICA, fastICA). No asumes ningún modelo sobre la señal, solo que son independientes y tipo de distribución.

$$d_\nu = As_\nu$$

- no-CIEGOS (e.g. métodos paramétricos). Útil si hay conocimiento previo del comportamiento de las señales

$$\chi^2 = \sum_{\nu} \frac{(d_{\nu} - m_{\nu})^2}{\sigma_{\nu}^2}$$

Separación de componentes

- * En este caso SÍ conocemos el comportamiento de cada una de las componentes podemos usar un **método paramétrico**:
- * maximum likelihood:

(caso sencillo asumiendo errores Gaussianos
es minimizar chi cuadrado)

$$\chi^2 = \sum_{\nu} \frac{(d_{\nu} - m_{\nu})^2}{\sigma_{\nu}^2}$$

donde el modelo es:

$$m_{\nu} = A_{cmb} f(\nu) + A_s \left(\frac{\nu}{\nu_0} \right)^{\beta} + A_d \left(\frac{\nu}{\nu_0} \right)^{\alpha+1} g(\nu) + \dots$$

los datos:

$$d_{\nu} = s_{\nu} + n_{\nu}$$

SEÑAL + RUIDO

y σ_{ν}^2 es la varianza del ruido a cada frecuencia

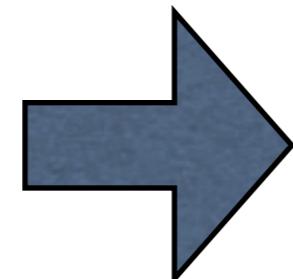
Separación de componentes

* maximum likelihood

Si todo fuera ideal, podríamos resolver de forma analítica

$$\frac{\partial \chi^2}{\partial \beta} = 0$$

$$\frac{\partial \chi^2}{\partial A_{cmb}} = 0$$



$$\beta = f_1(d_\nu, \vec{\theta})$$

$$A_s = f_2(d_\nu, \vec{\theta})$$

$$\alpha = f_3(d_\nu, \vec{\theta})$$

....

....

Separación de componentes

* maximum likelihood

Si todo fuera ideal:

$$\frac{\partial \chi^2}{\partial \beta} = 0$$

$$\frac{\partial \chi^2}{\partial A_{cmb}} = 0$$

....

Pero con datos no solemos estar en el caso ideal . Para el caso del CMB:

- * ni el ruido es Gaussiano
- * ni se puede resolver de manera analítica
- * hay sistemáticos, correlaciones del ruido, etc...

Separación de componentes

- Probamos un método nuevo: Redes Neuronales

Separación de componentes con Redes neuronales

- * Dados una serie de datos frecuenciales queremos encontrar unos parámetros
- * **Inputs** --> datos a cada frecuencia
- * **Outputs o labels** --> parámetros del modelo

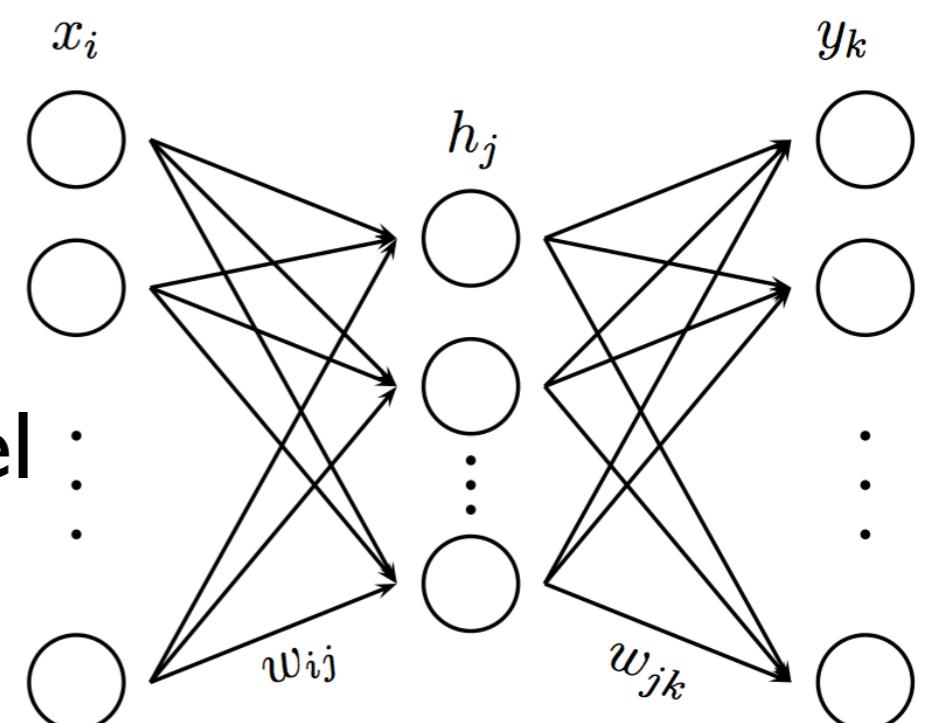
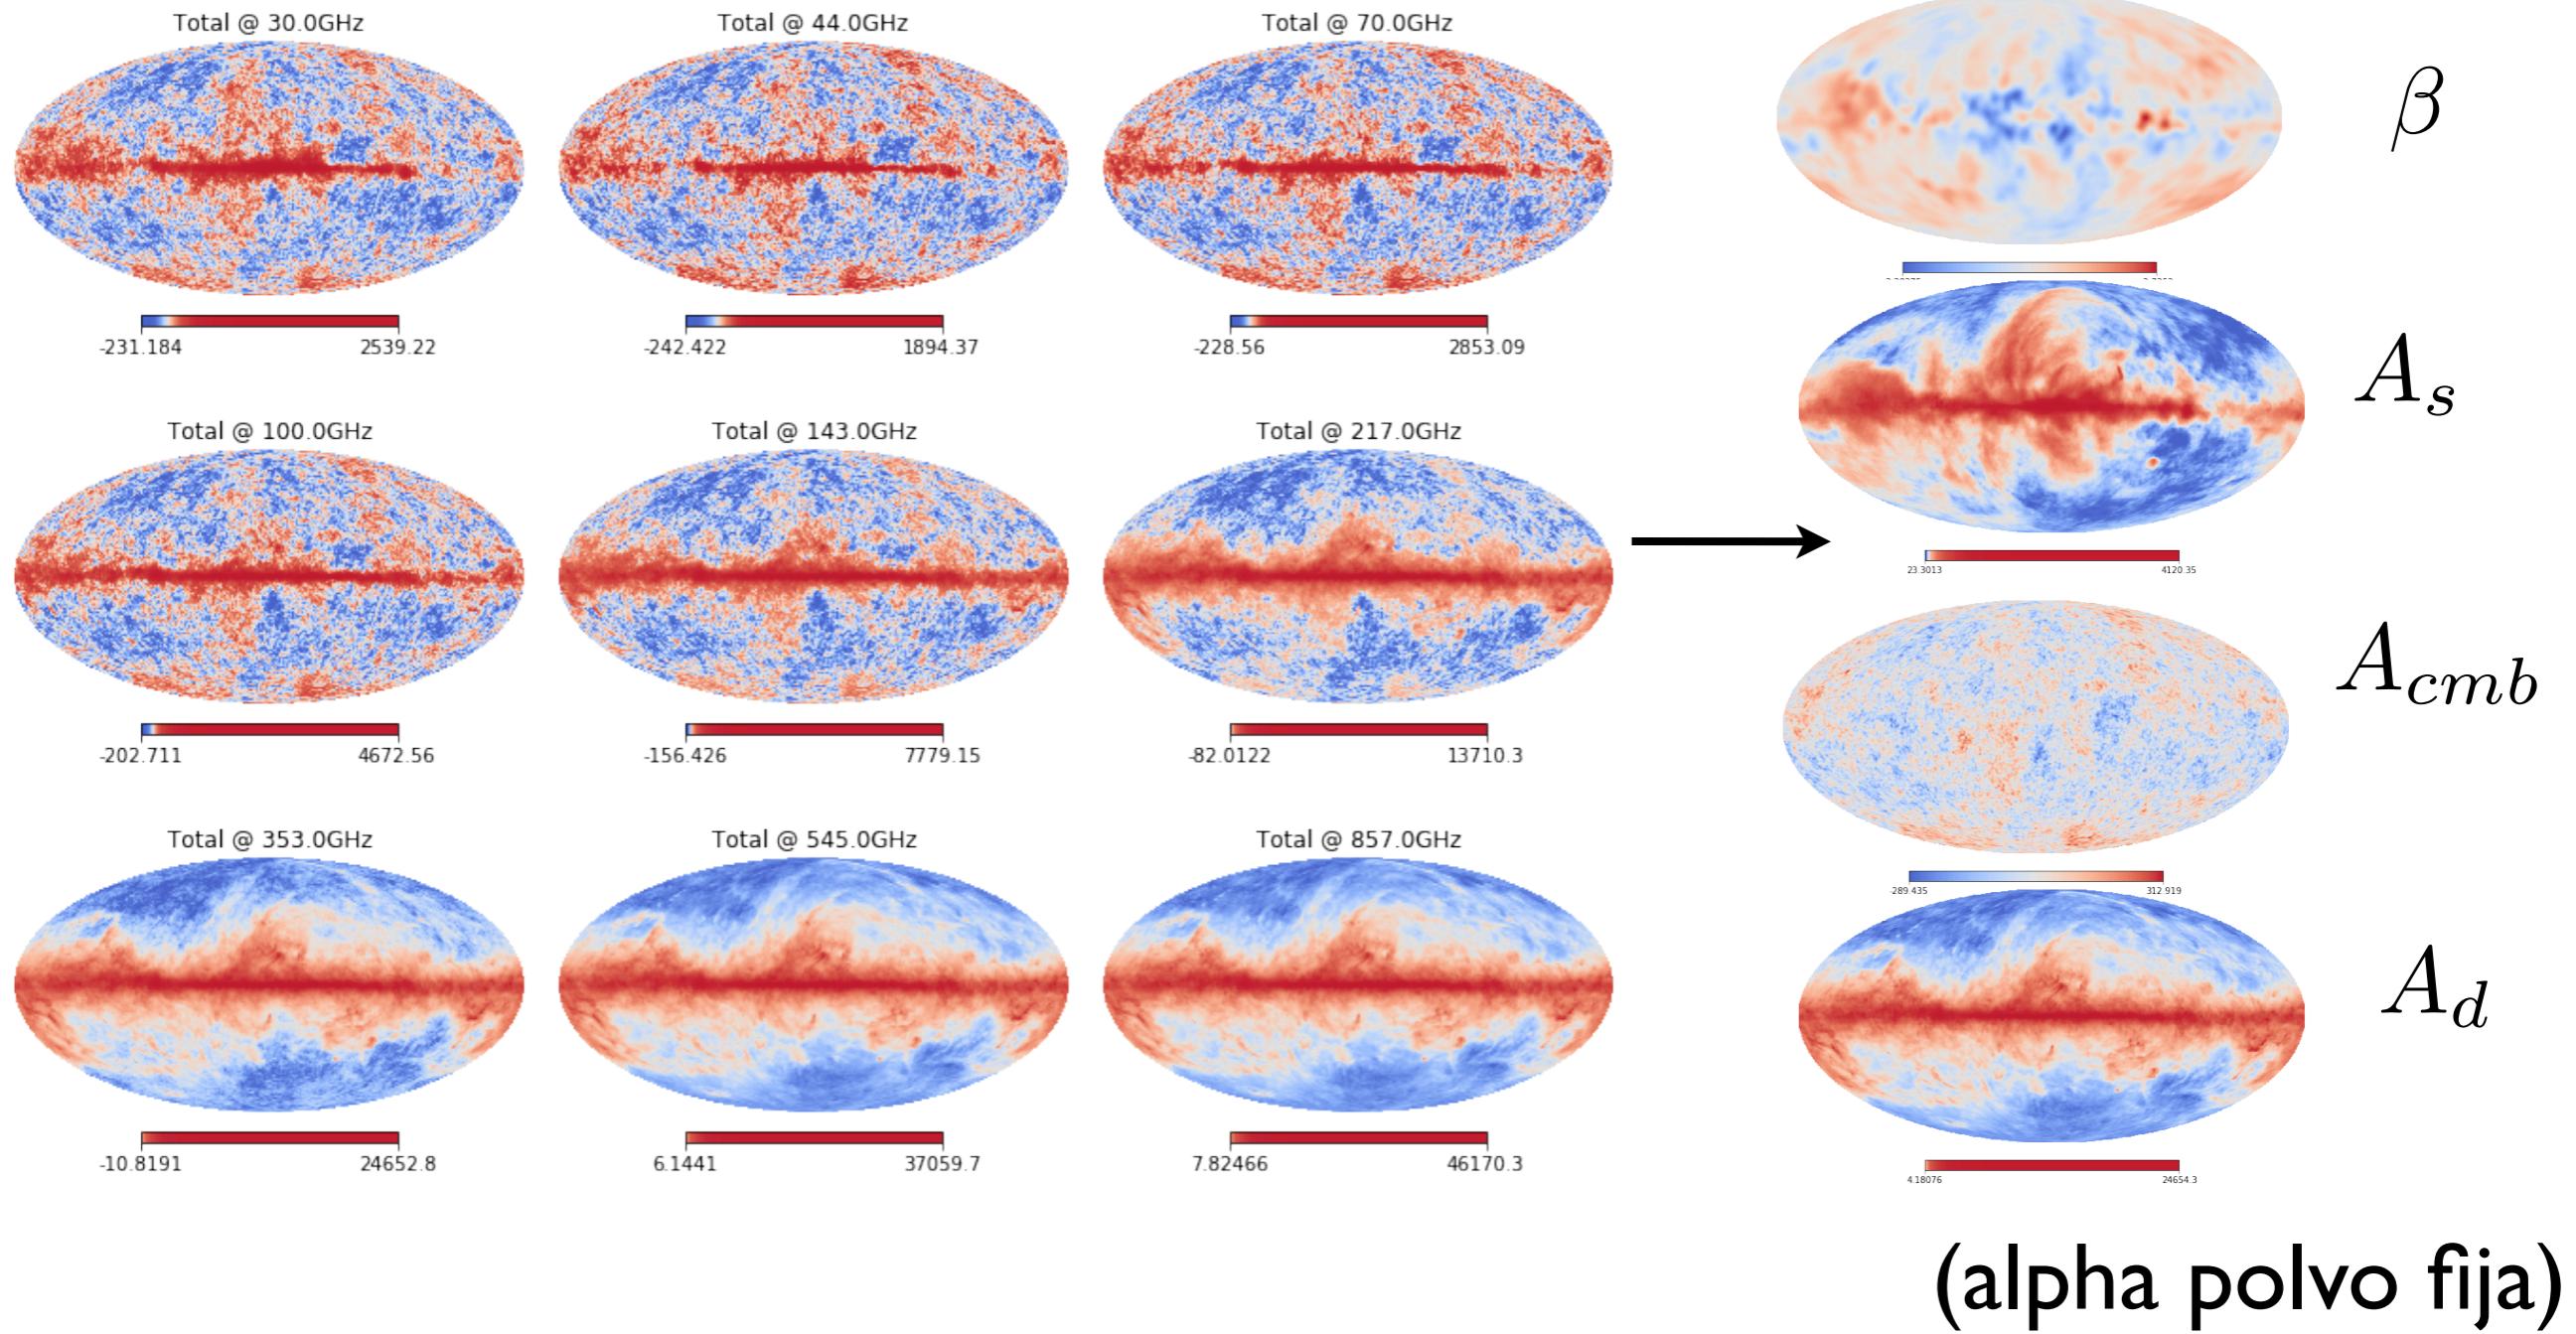
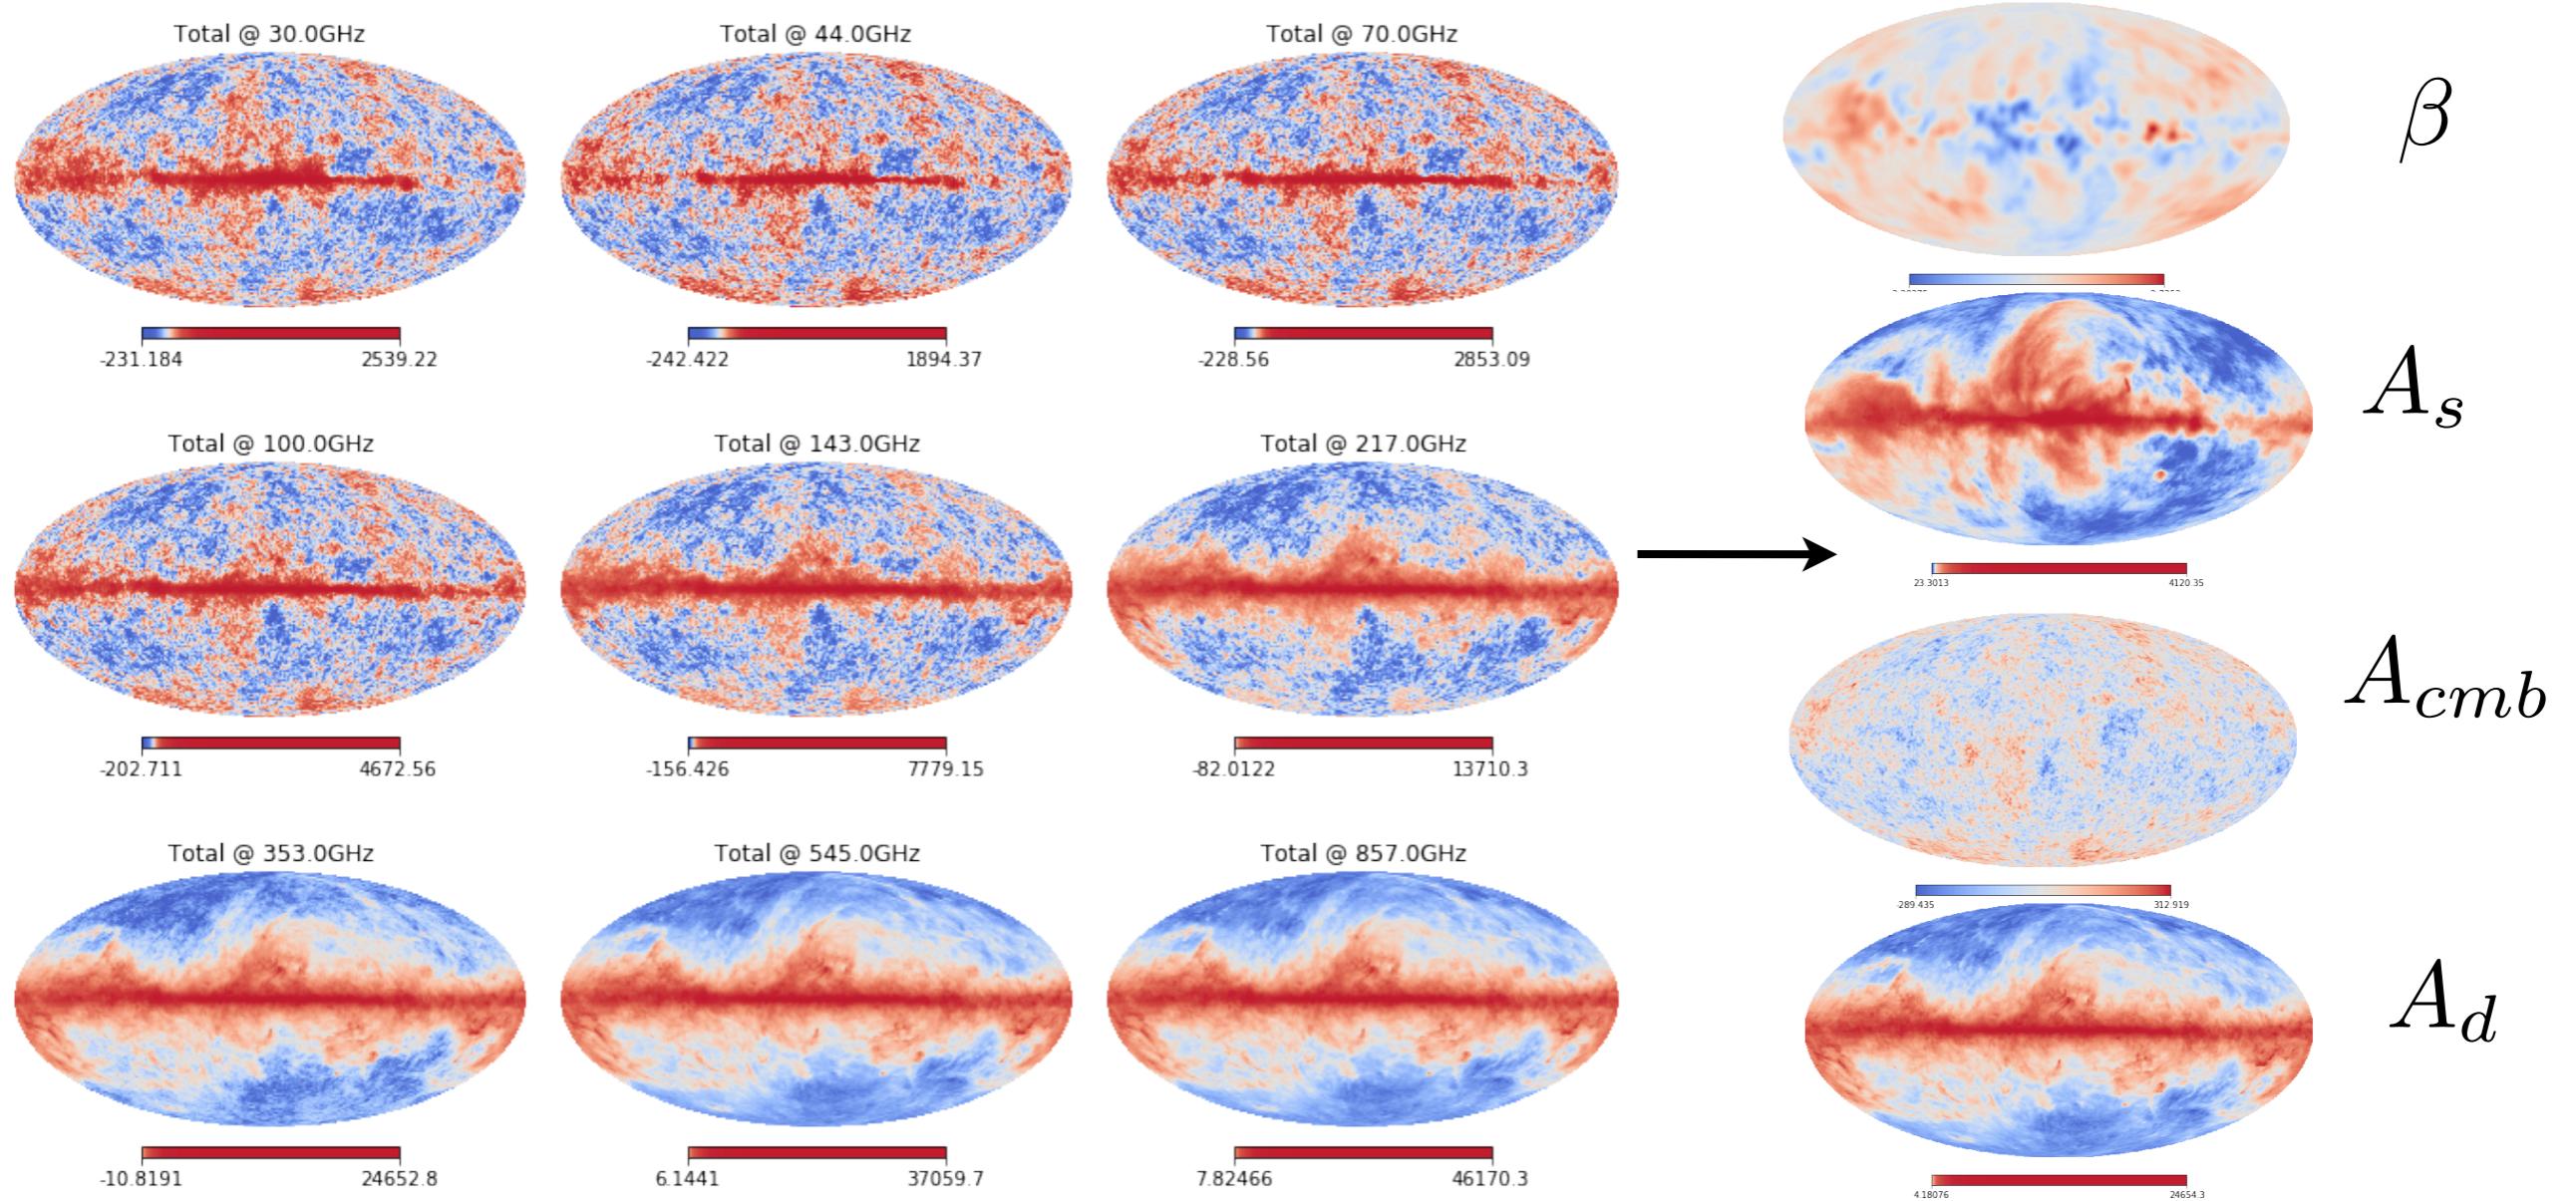


Figure 1. Schematic of a 3-layer feed-forward neural network.

Problema a resolver



Problema a resolver

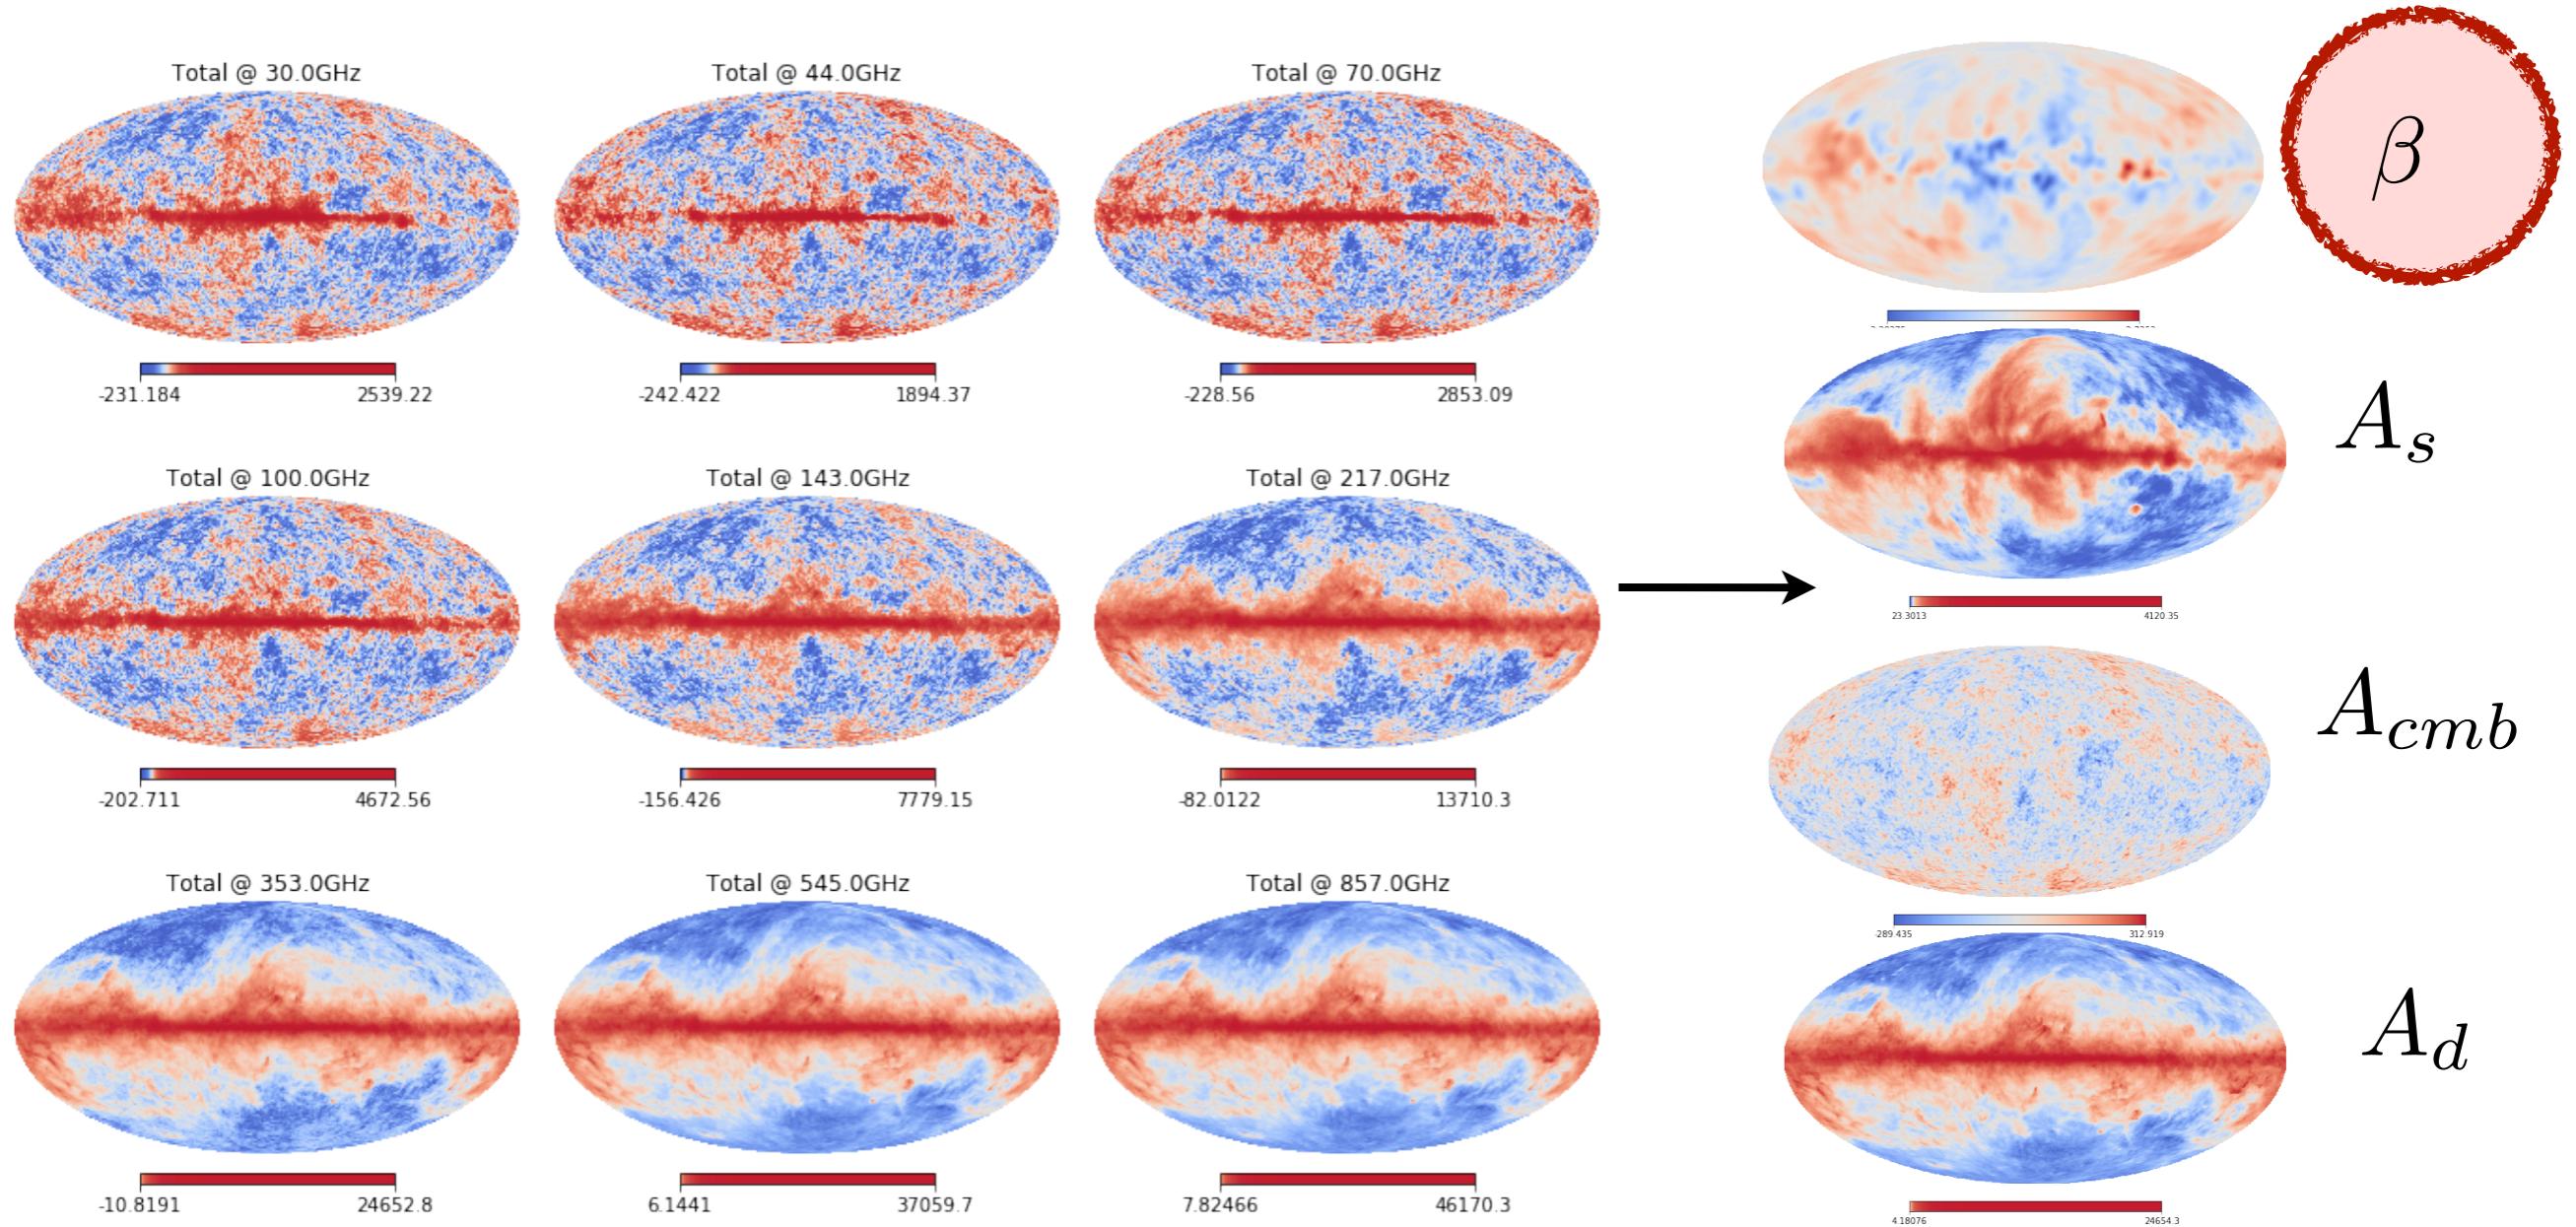


Inputs: 9 frecuencias

Outputs: 4 parámetros (en la realidad habría algunos más,...)

(alpha polvo fija)

Problema a resolver



Inputs: 9 frecuencias

Outputs: 4 parámetros (en la realidad habría algunos más,...)

(alpha polvo fija)

Problema a resolver

¿Cómo lo vamos a hacer?

Entrenando una red neuronal:

1. Dado un training set (señal en cada frecuencia, parámetros modelo)
 2. Configurar red
 3. Entrenar y obtener modelo
 4. Hacemos predicciones con unos datos (simulados)
-

Para hacer:

Notebook con ejercicio CompSepLab2020-Exercicie.ipynb.
Kaggle Challenge.

Problema a resolver

Training Set

* ¿Cómo hemos generado training set ?

- Lanzamos números aleatorios (con rangos realistas) para los parámetros $A_{cmb}, A_s, \beta_s, A_d$

- Calculamos el modelo m_ν

$$m_\nu = A_{cmb}f(\nu) + A_s \left(\frac{\nu}{\nu_o}\right)^\beta + A_d \left(\frac{\nu}{\nu_o}\right)^{\alpha+1} g(\nu)$$

- Generamos un valor aleatorio para ruido para cada frecuencia n_ν

- Y tenemos los datos simulados:

$$d_\nu = m_\nu + n_\nu$$

Problema a resolver

Training Set

* ¿Cómo hemos generado training set ?

- Lanzamos números aleatorios (con rangos realistas) para los parámetros $A_{cmb}, A_s, \beta_s, A_d$

- Calculamos el modelo m_ν

$$m_\nu = A_{cmb}f(\nu) + A_s \left(\frac{\nu}{\nu_o}\right)^\beta + A_d \left(\frac{\nu}{\nu_o}\right)^{\alpha+1} g(\nu)$$

- Generamos un valor aleatorio para ruido para cada frecuencia n_ν

- Y tenemos los datos simulados:

$$d_\nu = m_\nu + n_\nu$$

Inputs: $d_{30}, d_{44}, d_{70}, d_{100}, d_{217}, \dots$ --> dimensión: Número de frecuencias

Labels: $A_{cmb}, A_s, \beta_s, A_d$ --> dimensión: Número de parámetros

Separación de componentes con redes neuronales

- * Para leer mapas y visualizarlos vamos a usar **healpy**
 - /opt/conda/bin/python3.6 -m pip install healpy
 - o pip install healpy
- * Notebook para ejercicio: CompSepLab2020-Exercice.ipynb

Notebooks y data sets en google drive:
shorturl.at/eizJV